타이타닉

생성일	2026년 10월 27일 오후 11:18
태그	

1. 분석 목적과 진행 상태

한 행이 무엇을 뜻하는지부터 확인하고, 결측 처리에 따라 분석 대상이 어떻게 바뀌는지 기록한다. 생존율에는 항상 분모를 제시하고, 관찰된 차이·통계적 검정·미래 예측을 구분한다.

구분	진행 상태	산출물
원본 확보·검증	완료	train/test 사본, 다른 저장소 값 대조, SHA-256
컬럼 파악·품질 진단	완료	컬럼 사전, 결측·중복·범위 확인
EDA용 정제와 결측 제거	완료	결측 보존본, 별도 완전관측 정제본, 제외 사유
EDA	완료	집단별 생존율, 나이·요금·가족 규모 차트
탐색적 가설 4개	검정 완료	Fisher·카이제곱 검정, Holm 보정, 정제본 민감도 분석
남성 생존율 추가 분석	기술적 비교 완료	성별×등급·나이 비교, 역사적 자료와 해석 구분
팀 다변량 질문 10개	실제 분석·그래프 작성 완료	질문별 결과표·대표 검정·Holm 보정·그래프 10개·실행 자료: 16절
예측 모델 3종	학습·평가 완료	로지스틱 회귀·의사결정나무·랜덤 포레스트
test.csv 418명 생존 예측	생성 완료	확률·예측 CSV, Kaggle 제출 형식 CSV
Kaggle 제출	미실행	파일만 만들었고 업로드하지 않음

강의 범위와 추가 분석의 구분: 제공된 강의의 중심은 데이터 구조·결측·집단별 생존율 EDA다. 이 문서의 가설 4개, 16세 경계, 팀 질문 10개와 예측 모델 비교는 팀 활동을 위해 추가로 설정·구현한 내용이다. 가설 4개와 16세 기준을 교수님이 지정한 것으로 표현하지 않는다.

2. 데이터 출처와 실제 구조

원출처: Kaggle Titanic 대회 데이터

파일	실제 크기	생존 정답	이번 사용 목적
train.csv	891행 × 12열	Survived 있음	EDA·가설 검정·모델 학습과 내부 평가
test.csv	418행 × 11열	Survived 없음	품질·입력 구조 확인, 최종 예측
gender_submission.csv	이번 분석 입력으로 사용하지 않음	실제 정답표가 아님	제출 형식 예시

📌 **실제 다운로드 경로를 명시한다.** 이번 실행에서 Kaggle API 인증 정보가 없어 공개 GitHub 저장소 `agconti/kaggle-titanic`의 사본을 받았다. `minsuk-heo/kaggle-titanic`의 사본을 별도로 읽어 행·컬럼 값이 일치하는지 대조했다. 인증된 Kaggle 원본과 바이트가 동일하다고 확인한 것은 아니다. 두 사본은 줄바꿈 등 파일 바이트가 다를 수 있으며 원본 다운로드 주소·고정 커밋·체크섬을 기록했다.

- train.csv 다운로드 사본 · 독립 저장소 대조 사본
- test.csv 다운로드 사본 · 독립 저장소 대조 사본

파일	내려받은 사본의 SHA-256	다른 저장소 값 대조
train.csv	4a437fde05fe5264e1701a7387ac6fb75393772ba38bb2c9c566405af5af4bd7	행·컬럼 값 일치
test.csv	5c78320a80dc159b35c408363be46a5d93f078183d539db75ee42a796d6a4e95	행·컬럼 값 일치

관찰 단위는 승객 한 명이다. 첫 행의 PassengerId=1, Name=Braund, Mr. Owen Harris, Pclass=3, Sex=male, Age=22, Fare=7.25, Survived=0은 같은 승객의 속성이다. Survived=0은 사망, 1은 생존이다.

3. 전체 컬럼과 파생변수 이해

컬럼	의미	자료 유형	값·단위	해석 기준
PassengerId	승객 식별자	정수 식별자	승객 1명당 고유 번호	평균·상관계수 분석에서 제외

컬럼	의미	자료 유형	값·단위	해석 기준
Survived	생존 여부	이진 범주	0=사망, 1=생존	train에만 존재. test의 정답을 추정해 검정하지 않음
Pclass	객실 등급	순서형 범주	1=1등급, 2=2등급, 3=3등급	숫자 간 간격이 같은 연속변수로 해석하지 않음
Name	이름	문자열	승객 이름 및 호칭	한 행이 한 사람의 기록임을 확인하는 용도
Sex	기록된 성별	명목형 범주	female, male	각 범주의 인원과 생존율을 함께 제시
Age	나이	연속 수치·세	영아의 나이는 소수로 표현될 수 있음	결측이 있음. 16세 미만 구분은 이 분석의 정의
SibSp	동행 형제자매·배우자 수	비음수 정수·명	파일에 기록된 가족 동행자 수	친구·동료 등 모든 동행자를 포함하지 않음
Parch	동행 부모·자녀 수	비음수 정수·명	파일에 기록된 가족 동행자 수	가족관계 전체를 완전하게 복원하는 값은 아님
Ticket	승선권 번호	문자열 식별 정보	문자·숫자 혼합, 여러 사람이 공유할 수 있음	중복 승선권을 중복 승객으로 삭제하지 않음
Fare	기록된 승선 요금	비음수 연속 수치	당시 영국 파운드 기준 기록값	공유 승선권이 있어 개인별 지출로 단정하지 않음. 0·극단값 보존
Cabin	객실 번호	문자열 범주	여러 객실이 한 셀에 기록될 수 있음	결측이 매우 많아 원본·주 분석에서는 보존, 완전 관측 정제본에서는 열 제거
Embarked	승선 항구	명목형 범주	C=Cherbourg, Q=Queenstown, S=Southampton	숫자로 바꾼 코드의 평균·상관계수는 해석하지 않음

추가 변수	계산·정의	해석 기준
FamilySize	SibSp + Parch + 1	파일에 기록된 가족 동행자 수에 본인을 더한 값
Alone	FamilySize == 1	기록된 형제·배우자·부모·자녀 동행자가 없음
AgeBand	[0,16), [16,30), [30,50), [50,∞), Unknown	EDA 표시용 구간. 예측 모델은 나이 원값 사용
ChildGroup	Age가 관측된 경우 16세 미만 / 16세 이상, 나머지는 Unknown	임의로 결측 승객을 성인으로 분류하지 않음
AgeMissing 등	Age·Cabin·Embarked·Fare 각각의 결측 여부	결측 자체의 집단 차이를 진단하기 위한 표시

Alone은 실제 혼자 여행했다는 증명이 아니다. 친구·동료 등은 SibSp/Parch에 포함되지 않을 수 있다. 같은 Ticket이 여러 번 나와도 승객이 서로 다르면 중복 행으로 제거하지 않는다.

3.1 나이가 전부 정수이고 정확한가?

891명 중 나이가 기록된 사람은 714명, 결측은 177명이다. 관측 범위는 0.42~80세이고 정수 나이 기록은 689명, 소수 기록은 25명이다.

값 예시	의미
16.0, 21.0	각각 16세·21세로 기록됨
0.42	약 5개월인 영아의 나이
28.5, 70.5	소수 나이 기록. Kaggle은 추정 나이를 xx.5 형식으로 표시한다고 설명
빈칸	나이 미상

정수로 기록돼 있다는 사실만으로 실제 나이가 정확하게 확인됐다고 보장할 수는 없다. 영아·추정 나이 표기는 Kaggle 변수 설명을 따른다. 나이 원값은 바꾸지 않았다.

3.2 16세 기준의 출처와 한계

16세는 어린 나이의 승객과 나머지를 간단히 비교하려고 이번 탐색적 분석에서 선택한 기준이다. 교수님 지정, Kaggle 지정, 법적·역사적 어린이 구분, 데이터에서 찾은 최적 경계가 아니다. 16세인 승객은 `Age >= 16` 집단에 속한다.

이 기준의 검정은 "두 집단의 생존 비율이 다른가?"에 답한다. "나이가 증가하면서 생존율이 어떻게 변하는가?" 전체를 설명하는 분석은 아니다. 앞으로 전체 연령 경향을 보려면 구간 기준을 먼저 명시하거나 나이 원값을 사용하는 분석을 설계한다. 유의한 결과가 나오는 경계를 사후에 고르지 않는다.

4. 결측 진단과 정제 기준

컬럼	train 결측	test 결측
Age	177/891명 (19.87%)	86/418명 (20.57%)
Cabin	687/891명 (77.10%)	327/418명 (78.23%)

컬럼	train 결측	test 결측
Embarked	2/891명 (0.22%)	0/418명 (0.00%)
Fare	0/891명 (0.00%)	1/418명 (0.24%)

4.1 품질 점검에서 확인한 사항

- train/test 모두 완전 중복 행 0건, 중복 PassengerId 0건이다.
- Pclass·Sex·Embarked 범주와 수치의 음수·정수 여부 등을 확인했다.
- 이름 앞뒤 공백은 train 2개 셀, test 2개 셀을 정리했다. 원본 파일 자체를 수정한 것은 아니다.
- 요금 0과 큰 요금은 오류라는 근거가 없어 보존했다. 상자그림에서 이상값 점을 숨긴 것은 자료 삭제와 다르다.
- 원본 파일의 분석 전후 SHA-256이 일치하는지 확인했다.

4.2 두 가지 EDA용 데이터를 별도로 보관

① 결측 보존본 prepared — 주 EDA와 가설 검정

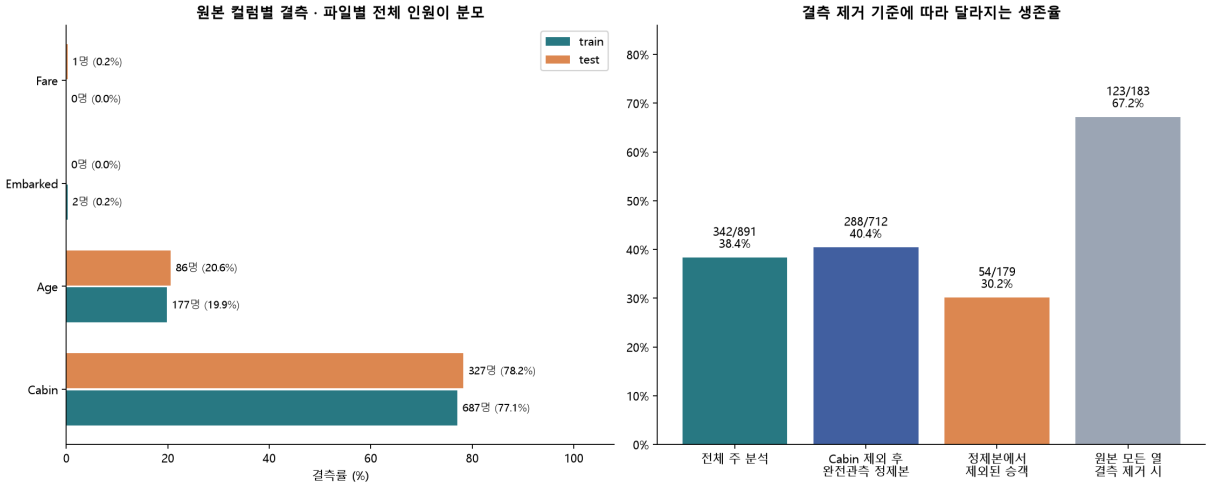
공백·범주를 정리하고 파생변수를 추가한다. 원래 결측은 유지하고 각 분석에 필요한 컬럼이 있는 행을 사용한다. 성별·등급·가족 동행 비교는 891명, 나이 비교는 나이가 기록된 714명이 대상이다. 나이를 평균으로 대체하지 않는다.

② 완전관측 정제본 completecase — 결측 제거 전후 비교

1. Cabin은 학습 데이터의 77.1%가 결측이므로 이 정제본에서 컬럼을 제외한다.
2. 나머지 원본 컬럼 중 하나라도 결측인 행을 제거한다. 파생된 결측 표시를 행 제거 기준으로 쓰지는 않는다.
3. train은 Age 177명과 Embarked 2명, 총 179명을 제외해 712명이 남는다.
4. test는 Age 86명과 Fare 1명, 총 87명을 제외해 331명이 남는다.
5. 제외한 PassengerId와 결측 컬럼을 별도 CSV에 기록한다.

처리 기준	학습 인원	생존자	생존율
전체 학습 데이터	891	342	38.4%
Cabin 열 제외 후 결측 행 제거	712	288	40.4%
위 기준으로 제외된 승객	179	54	30.2%
모든 원본 컬럼에 대해 바로 dropna	183	123	67.2%

결측 제거 후 생존율이 달라졌다. 이는 삭제 기준에 따라 분석 대상의 구성이 달라진다는 실제 사례다. 결측이 무작위라고 가정하지 않았고, 712명 정제본이 전체를 그대로 대표한다고 해석하지 않았다. "결측률이 특정 수치 이상이면 무조건 컬럼 삭제"라는 일반 규칙을 설정한 것도 아니다.



▼ 결측 확인·별도 정제본 생성의 핵심 코드

```
import pandas as pd
```

```python
train = pd.read_csv('data/raw/train.csv')
test = pd.read_csv('data/raw/test.csv')

print(train.shape, test.shape)
print(train.isna().sum().sort_values(ascending=False))
print(train.isna().mean().mul(100).sort_values(ascending=False))

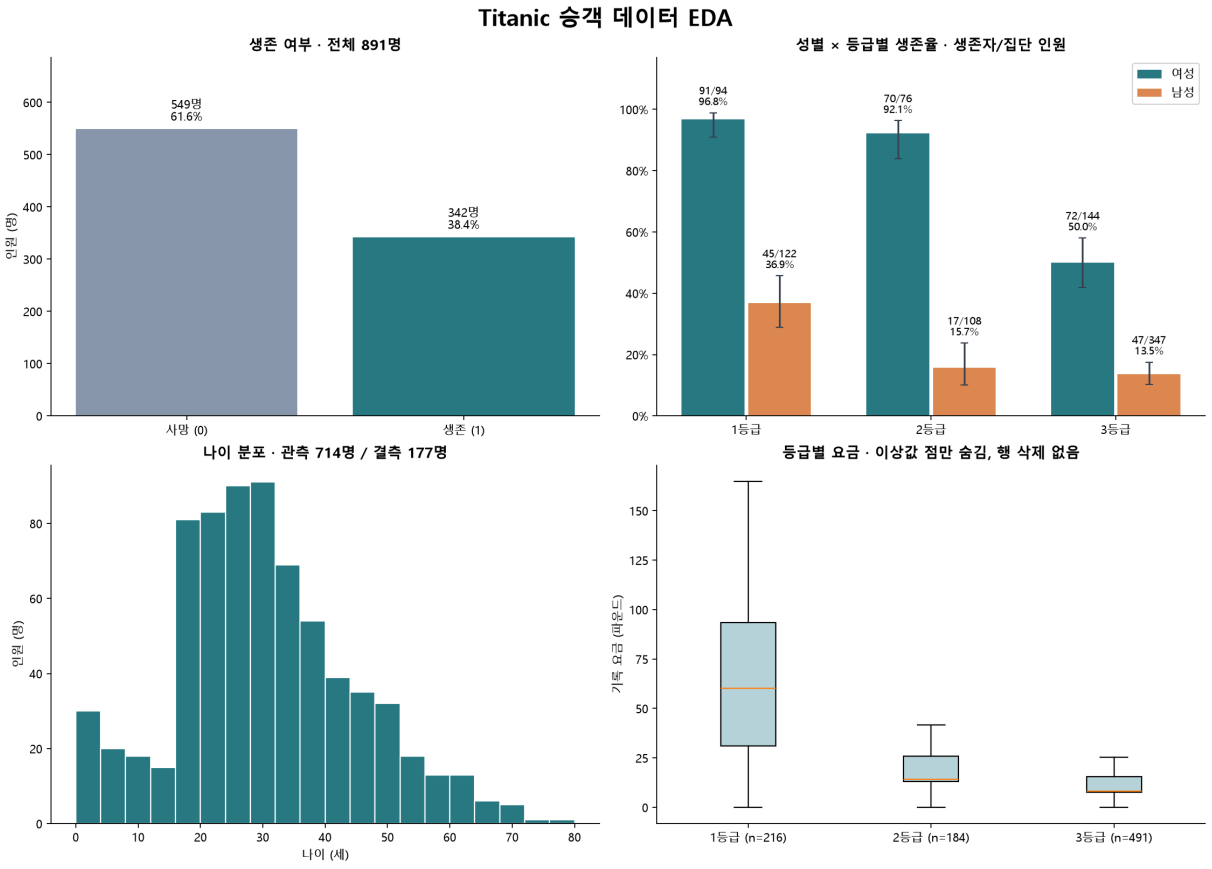
train_completecase = train.drop(columns=['Cabin']).dropna().copy()
test_completecase = test.drop(columns=['Cabin']).dropna().copy()

print(len(train_completecase), len(test_completecase))  # 712, 331
```

전체 실행 코드에는 공백 정리·범주와 수치 검증·파생변수·제외 사유 기록·원본 보존 검증도 들어 있다.

5. EDA: 인원·생존율·나이·요금·가족 규모

생존율은 `Survived=1인 수 / 해당 집단 전체 인원`이다. 전체 사망은 549명(61.6%), 생존은 342명(38.4%)이다.



5.1 성별 × 객실 등급별 생존율

성별	등급	집단 인원	생존자	생존율
여성	1	94	91	96.8%
여성	2	76	70	92.1%
여성	3	144	72	50.0%
남성	1	122	45	36.9%
남성	2	108	17	15.7%
남성	3	347	47	13.5%

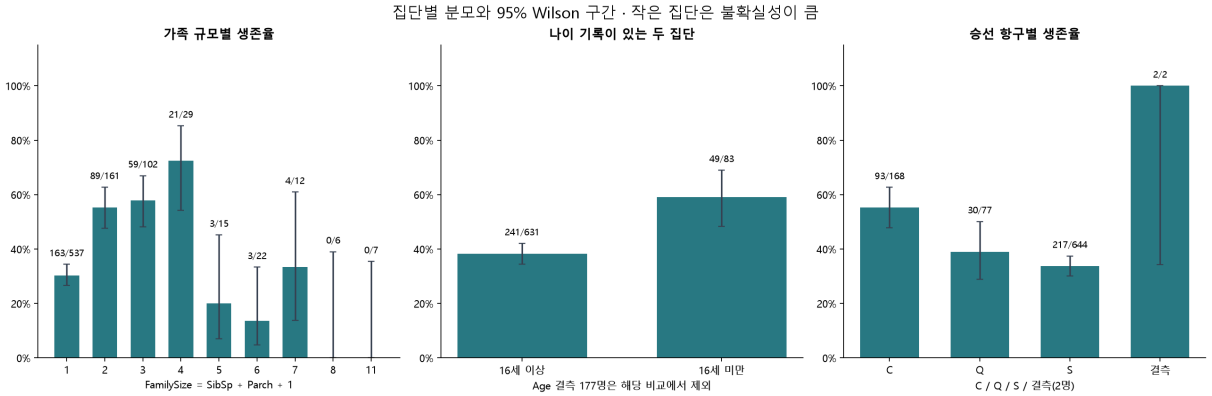
여성 1등급은 91/94명(96.8%), 여성 3등급은 72/144명(50.0%)이다. 여성·남성이라는 큰 구분 안에서도 등급별 차이가 있으므로 전체 평균만으로 집단 특성을 설명하지 않는다.

5.2 나이와 요금 분포

- 나이 히스토그램에는 나이가 기록된 714명만 포함된다. 분모가 전체 891명과 다르다.
- 요금은 치우친 분포이므로 평균과 중앙값을 구분해 본다.
- 요금 상자그림에서는 극단값 점만 숨겼으며 실제 원자료는 삭제하지 않았다.

등급	인원	요금 중앙값(파운드)	기록된 최댓값
1	216	60.2875	512.3292
2	184	14.2500	73.5000
3	491	8.0500	69.5500

5.3 가족 규모와 승선 항구



FamilySize는 1, 2, 3, 4, 5, 6, 7, 8, 11이 관측된다. 큰 규모 집단은 인원이 적으므로 생존율의 0%·100%만 보고 강한 결론을 내리지 않는다. 그림의 오차막대는 집단별 비보정 95% Wilson 구간이다. 항구 결측 2명의 100% 생존율도 2명이라는 작은 분모와 함께 읽어야 한다.

▼ 집단별 분모와 생존율 집계 코드

```
rates = train.groupby(['Sex', 'Pclass'])['Survived'].agg(
    n='size', survivors='sum', survival_rate='mean'
)
print(rates)

train['FamilySize'] = train['SibSp'] + train['Parch'] + 1
print(train.groupby('FamilySize')['Survived'].agg(['size', 'sum', 'mean']))
```

PassengerId는 식별자이고 Pclass·Embarked는 범주다. 숫자로 저장되거나 숫자로 바꿀 수 있다는 이유만으로 일괄 평균·숫자 코드 상관계수를 해석하지 않았다.

6. 탐색적 가설 4개: 정의·방법·결과

이 네 가설은 팀 활동을 위해 이번 분석에서 추가로 설정한 질문이다. 제공된 강의에서 교수님이 네 개를 지정한 것으로 쓰지 않는다. 분석 기준은 `analysis-plan.json`에 기록했다. 이미 알려진 교육용 자료를 탐색한 결과이며 독립적인 확증 연구가 아니다.

6.1 공통 검정 기준

- 귀무가설(H0)은 차이나 연관이 없다는 출발 가정이다.
- H1·H3·H4는 2×2 인원표의 **양측 Fisher 정확 검정**이다. 어느 방향이 높을지 미리 고정하지 않고 차이를 검정한다.
- H2는 3×2 인원표의 **Pearson 카이제곱 독립성 검정**이다. 최소 기대빈도 70.63으로 모든 기대빈도가 5 이상임을 확인했다.
- 유의수준은 0.05다. 네 주 검정의 p값에 **Holm 다중검정 보정**을 적용했다.
- p값은 H0와 검정 조건이 맞을 때 관측된 정도 또는 더 극단적인 결과가 나올 가능성이다. H0가 참일 확률이나 결론이 틀릴 확률 그 자체가 아니다.

가설	검정 인원	방법	원 p값	Holm 보정 p값	판정
H1	891	양측 Fisher 정확 검정	6.46e-60	2.59e-59	귀무가설 기각
H2	891	Pearson 카이제곱	4.55e-23	1.36e-22	귀무가설 기각
H3	714	양측 Fisher 정확 검정	0.000342	0.000342	귀무가설 기각
H4	891	양측 Fisher 정확 검정	1.86e-09	3.71e-09	귀무가설 기각

6.2 H1 — 성별 두 집단의 생존 비율이 같은가?

- H0: 여성과 남성의 생존 비율이 같다.
- H1: 두 비율이 다르다.
- 대상: 여성 314명, 남성 577명, 총 891명.
- 관찰: 여성 233/314명(74.2%), 남성 109/577명(18.9%).
- 효과: 여성−남성 **+55.3%p**. 비보정 95% Newcombe 비율차 구간은 약 +49.2~+60.7%p다.
- 판정: Holm 보정 $p \approx 2.59 \times 10^{-59}$로 H0 기각. 관찰된 성별 차이가 크지만 성별 자체의 인과효과를 입증한 것은 아니다.

6.3 H2 — 객실 등급과 생존 여부는 독립인가?

- H0: 등급과 생존 여부가 독립이다.
- H1: 등급과 생존 여부에 연관이 있다.
- 대상: 1등급 216명, 2등급 184명, 3등급 491명, 총 891명.
- 관찰: 1등급 136/216명(63.0%), 2등급 87/184명(47.3%), 3등급 119/491명(24.2%).
- 효과: $\chi^2 \approx 102.89$, 자유도 2, Cramer's $V \approx 0.340$.
- 판정: Holm 보정 $p \approx 1.36 \times 10^{-22}$로 H0 기각. 이는 세 등급 전체의 연관 검정이며 특정 등급 쌍별 차이나 단조 추세를 각각 검정한 결과는 아니다.

6.4 H3 — 16세 미만과 16세 이상의 생존 비율이 같은가?

- H0: 두 나이 집단의 생존 비율이 같다.
- H1: 두 비율이 다르다.
- 기준: Age < 16 / Age ≥ 16. 16세 경계는 이번 분석용 정의다.
- 대상: 나이 결측 177명을 이 검정에서만 제외한 714명.
- 관찰: 16세 미만 49/83명(59.0%), 16세 이상 241/631명(38.2%).
- 효과: 16세 미만−16세 이상 **+20.8%p**. 비보정 95% 비율차 구간은 약 +9.4~+31.5%p다.
- 판정: Holm 보정 $p \approx 0.000342$로 H0 기각. 나이가 기록된 승객을 대상으로 한 두 집단 차이이며 전체 연령 경향이나 역사적 어린이 우선 기준을 입증하지 않는다.

6.5 H4 — 가족 동행 기록 유무에 따른 생존 비율이 같은가?

- H0: 가족 동행 기록이 있는 집단과 없는 집단의 생존 비율이 같다.
- H1: 두 비율이 다르다.
- 기준: FamilySize ≥ 2 / FamilySize == 1.
- 대상: 동행 기록 있음 354명, 없음 537명, 총 891명.
- 관찰: 있음 179/354명(50.6%), 없음 163/537명(30.4%).
- 효과: 있음−없음 **+20.2%p**. 비보정 95% 비율차 구간은 약 +13.7~+26.6%p다.
- 판정: Holm 보정 $p \approx 3.71 \times 10^{-9}$로 H0 기각. 기록된 가족 동행과 생존의 연관이며 실제 혼자 여행했는지 또는 가족 때문에 생존했는지는 확정할 수 없다.

6.6 결측 제거 정제본에서 다시 확인

가설	정제본 검정 인원	Holm 보정 p값	판정
H1	712	7.55e-47	귀무가설 기각

가설	정제본 검정 인원	Holm 보정 p값	판정
H2	712	5e-20	귀무가설 기각
H3	712	0.000325	귀무가설 기각
H4	712	2.94e-07	귀무가설 기각

712명 정제본에서도 네 개 모두 같은 판정이 나왔다. 이 네 민감도 검정은 주 검정과 별도 묶음으로 Holm 보정했다. 같은 판정이라고 해서 결측 제거가 편향을 없앴다는 뜻은 아니다.

해석의 한계: 가족·동일 승선권 안의 승객은 독립적이지 않을 수 있다. 이 네 검정은 그 상관을 보정하지 않았으므로 p값과 구간은 독립 관측 가정하의 교육용 참고값이다. 집단별 Wilson 구간과 비율차 Newcombe 구간은 개별 비보정 95% 구간이며, Holm 보정 p값과 구분한다. H0 기각 실패는 두 집단이 같다는 증명이 아니다.

▼ 실제로 사용한 검정 방법의 핵심 코드

```
from scipy.stats import fisher_exact, chi2_contingency
from statsmodels.stats.multitest import multipletests

# H1: 행=여성/남성, 열=생존/사망
h1 = fisher_exact([[233, 81], [109, 468]], alternative='two-sided')

# H2: 행=등급, 열=사망/생존
class_table = pd.crosstab(train['Pclass'], train['Survived'])
h2 = chi2_contingency(class_table, correction=False)

# 전체 코드에서는 H3·H4도 정의한 집단의 실제 인원표로 검정한다.
# 네 p값을 모아 multipletests(p_values, alpha=0.05, method='holm') 적용.
```

전체 데이터 준비·검정 코드와 구간 계산은 첨부 ZIP의 `titanic_eda.py` 및 실행된 노트북에 있다.

7. 남성 생존율이 낮은 이유를 어디까지 분석할 수 있는가?

7.1 등급 구성의 차이

남성 중 3등급 비중은 347/577명(60.1%), 여성 중에서는 144/314명(45.9%)이다. 생존율이 낮은 등급에 남성이 더 많이 포함된 구성 차이가 있다.

7.2 같은 등급에서도 차이가 유지되는가?

등급	남성 생존자/인원	남성 생존율	여성 생존자/인원	여성 생존율
1	45/122	36.9%	91/94	96.8%
2	17/108	15.7%	70/76	92.1%
3	47/347	13.5%	72/144	50.0%

세 등급 모두 남성 생존율이 낮다. 따라서 남성에 3등급 승객이 많다는 설명만으로 전체 성별 차이를 설명하기는 어렵다. 같은 등급이어도 나이·객실 위치·대피 상황까지 같다는 뜻은 아니다.

7.3 남성 안에서도 나이에 따라 다르다

나이가 기록된 남성 453명에서 앞서 정한 분석용 16세 경계를 적용하면, 16세 미만은 21/40명(52.5%), 16세 이상은 72/413명(17.4%)이 생존했다. 나이 미상 남성 124명은 이 비교에서 제외했다.

추가로 남성의 가족 동행 기록이 없으면 64/411명(15.6%), 있으면 45/166명(27.1%)이 생존했다. 이 비교는 성별 내부에서도 다른 조건을 함께 볼 필요가 있음을 보여주는 기술적 관찰이며 추가 가설 검정 결과로 제시하지 않는다.

7.4 역사적 설명과 데이터 분석을 구분한다

미국 상원 조사보고서에는 여성과 어린이를 우선 구명정에 태웠고, 배의 양쪽에서 탑승 방식이 달랐다고 기록돼 있다. 이는 관측된 성별 차이와 부합하는 역사적 설명이다. 조사보고서 전사본

현재 CSV에는 개인별 구명정 탑승 시도·구조 순서·대피 경로·당시 위치와 행동이 없다. 따라서 각 남성의 사망 원인, 우선 구조 방침이 성별 차이의 몇 %를 설명하는지, 특정 등급에서 정책이 실제로 얼마나 준수됐는지까지 확정하지 않는다.

8. 팀 질문 10개 — 변수·기준·결과 단위를 고정한 설계안

🧭 **아래는 최초 설계한 질문 10개이며 실제 분석을 모두 완료했다.** 최신 결과표·그래프·보정 p값·해석 범위는 16절에서 확인한다. 앞 절의 검정 완료 가설 4개와 구분한다. 교수님이 지정한 질문이 아니라 이번 팀 활동을 위해 추가로 만든 질문이다. 1~9번은 train.csv, 10번은 train/test 비교를 사용한다. 분석에 필요한 값이 있는 행과 제외 인원을 기록한다.

Q1. 같은 성별·등급 안에서 나이가 많은 승객일수록 기록 요금도 높은가?

- 유형: 수치×수치×범주.
- 변수: Age, Fare, Sex, Pclass.
- 산출: 성별×등급 6개 집단의 스피어만 상관계수(-1~1), 분석 인원, 상관 방향.

Q2. 같은 등급에서 가족 규모가 클수록 기록 요금도 높은가? 남녀의 관계는 같은가?

- 유형: 수치×수치×범주.
- 변수: FamilySize=SibSp+Parch+1, Fare, Sex, Pclass.
- 산출: 집단별 상관계수와 가족 규모별 요금 중앙값. 기록 요금을 개인 지출액으로 단정하지 않는다.

Q3. 같은 등급에서 여성과 남성의 요금 중앙값은 몇 파운드 차이 나는가?

- 유형: 수치×범주×범주.
- 변수: Fare, Sex, Pclass.
- 산출: 집단 인원, 요금 중앙값, 여성 중앙값−남성 중앙값(파운드).

Q4. 같은 성별·등급에서 생존자와 사망자의 나이 중앙값은 몇 세 차이 나는가?

- 유형: 수치×범주×범주.
- 변수: Age, Survived, Sex, Pclass.
- 산출: 관측 나이 인원, 나이 중앙값, 생존자 중앙값−사망자 중앙값(세). 나이를 특정 기준으로 둘로 나누지 않는다.

Q5. 여성−남성 생존율 차이는 세 등급에서 각각 몇 %p이며 어느 등급에서 큰가?

- 유형: 범주×범주×범주.
- 변수: Sex, Pclass, Survived.
- 산출: 등급별 여성 생존율−남성 생존율, 각 집단 인원·생존자·구간. 기존 EDA를 출발점으로 차이의 차이와 불확실성을 구체화할 질문이다.

Q6. 성별·등급이 같아도 항구 C·Q·S에 따라 생존율이 다른가?

- 유형: 범주×범주×범주×범주.
- 변수: Embarked, Sex, Pclass, Survived.
- 산출: 각 성별×등급 안에서 항구별 인원·생존자·생존율·항구 간 차이(%p). 작은 집단 인원을 함께 제시한다.

Q7. 나이 누락 집단과 관측 집단의 생존율 차이는 성별·등급에 따라 달라지는가?

- 유형: 결측 여부×범주×범주×범주.
- 변수: AgeMissing, Sex, Pclass, Survived.
- 산출: 성별×등급별 나이 결측률과 결측 집단−관측 집단 생존율 차이. 결측 자체가 변수이므로 결측 승객도 포함한다.

Q8. 성별·등급이 같아도 Cabin 기록 유무에 따라 요금 중앙값이 다른가?

- 유형: 수치×결측 여부×범주.
- 변수: Fare, Cabin 기록 여부, Sex, Pclass.
- 산출: 집단 인원, 요금 중앙값, 두 중앙값의 차이. 객실 실제 보유 여부와 기록 유무를 구분한다.

Q9. 같은 승선권 승객의 생존 결과는 성별·등급을 고려해도 더 비슷한가?

- 유형: 집단 식별자×범주×범주.
- 대상: train.csv 안에서 동일 Ticket을 가진 승객이 2명 이상인 집단.
- 산출: 가능한 승객 쌍 중 둘 다 생존하거나 둘 다 사망한 쌍의 비율.
- 비교 기준: 성별×등급 안에서 생존 결과를 무작위로 섞는 과정을 10,000회 반복한 기준 분포. 승선권별 인원은 파일에서 관측된 인원으로 한정한다.
- 상태: 성별·등급 안의 10,000회 순열 분석을 실행했다. 실제 일치율 76.07%, 조건부 무작위 기준 평균 57.89%다. 자세한 결과는 16절 Q9에 있다. 기존 예측 모델 비교의 2,000회 그룹 부트스트랩과는 별도 작업이다.

Q10. 같은 성별·등급에서 train/test의 나이·요금·결측률은 얼마나 다른가?

- 유형: 수치×수치×범주×데이터 구분.
- 변수: Age, Fare, Sex, Pclass, train/test 구분.
- 산출: 6개 집단의 나이 중앙값 차이(세), 요금 중앙값 차이(파운드), 나이·요금 결측률 차이(%p).
- test의 생존 정답을 추정해 비교하지 않는다.

질문별 대표 검정 하나씩 총 10개 p값을 Holm 보정해 분석했다. 결과와 한계는 16절에 기록했다. 분석 완료는 모든 가설이 맞았다는 뜻이 아니며, 6개 대표 귀무가설 기각·4개 근거 부족으로 구분한다.

9. 예측 모델링: 무엇을 실제로 학습했는가?

기존에는 EDA와 Fisher·카이제곱 검정만 수행했다. 이후 요청에 따라 다음 세 모델을 실제로 학습하고 성능을 비교했다.

모델	예측 방식	이번 역할
로지스틱 회귀	입력 변수로 생존 로그오즈·확률 계산	기본 분류 모델, 수치 표준화 사용
의사결정나무	변수 조건으로 승객을 단계적으로 분리	비선형 분류와 분기 구조 확인
랜덤 포레스트	서로 다른 표본·변수 후보로 만든 나무 300개 결합	나무 앙상블 성능 비교
Dummy 기준선	학습 구간 생존 비율을 모두에게 적용하고 다수 클래스로 분류	단순 예측보다 얼마나 개선됐는지 확인

9.1 동일한 7개 입력과 제외 변수

역할	컬럼	처리
수치 입력	Age, Fare, SibSp, Parch	학습 중앙값 대체, 학습에서 관측된 결측 표시 추가
범주 입력	Pclass, Sex, Embarked	학습 최빈값 대체, 원핫 인코딩
정답	Survived	입력에 포함하지 않음
식별자·고유 문자열	PassengerId, Name	이번 기본 모델 입력에서 제외
분리용 그룹	Ticket	같은 승선권 일행을 같은 구간에 묶는 용도로만 사용
이번 모델에서 제외	Cabin	결측이 많아 기본 비교에서는 제외

FamilySize·Alone은 EDA에서 만들었지만 이번 세 모델의 공통 입력에는 넣지 않았다. SibSp·Parch의 원값을 사용했다. 나이도 원값이며 16세 경계를 예측 모델에 넣지 않았다.

9.2 정보 누출을 막는 학습·평가 분리

1. 정답이 있는 원본 891명 전원을 사용한다. 결측 때문에 승객을 삭제하지 않는다.
2. Ticket을 앞뒤 공백 제거·대문자로 통일해 그룹을 정의한다.
3. `StratifiedGroupKFold(n_splits=5, shuffle=True, random_state=42)`의 첫 분할을 고정해 개발용 712명, 최종 평가용 179명으로 나눈다.
4. 개발용은 생존 273명/사망 439명, 최종 평가용은 생존 69명/사망 110명이다.
5. 개발용 543개 Ticket 그룹과 평가용 138개 그룹 사이의 중복은 0개다.
6. 개발용 712명 안에서 random_state=2026의 5겹 그룹 교차검증으로 설정을 탐색한다. 각 학습·검증 폴드 사이에도 Ticket이 겹치지 않는다.
7. 중앙값·최빈값·원핫 인코딩·로지스틱 표준화는 Pipeline 안에서 **각 학습 구간으로만** 학습한다. 평가 구간이나 test.csv를 합쳐 통계를 계산하지 않는다.

⚠️ **숫자는 같지만 다른 712명이다.** EDA 정제본의 712명은 Cabin 제외 후 결측 행을 제거해 남은 사람이다. 모델 개발용 712명은 원본 891명을 Ticket 그룹 기준으로 분리한 사람이다. 모델 개발용에도 나이 결측 승객이 포함되며, 학습 안에서 값을 대체한다. 대체한 값으로 원본이나 기존 EDA 정제본을 덮어쓰지 않았다.

9.3 설정 탐색과 모델 선택 기준

선택 기준은 **개발용 5겹 그룹 교차검증의 평균 ROC-AUC**다. 최종 평가 179명의 점수를 보기 전에 모델과 설정을 선택했다.

모델	탐색 범위	후보 수
로지스틱 회귀	C=0.1·1·10, class_weight=None·balanced, max_iter=3000	6
의사결정나무	max_depth=3·5·8·제한 없음, min_samples_leaf=2·5·10	12
랜덤 포레스트	나무 300개, max_depth=5·10·제한 없음, min_samples_leaf=1·3·5, max_features=sqrt·0.8	18

모델	CV AUC 평균 ± 표준편차	CV 정확도 평균	선택한 설정
랜덤 포레스트	0.848 ± 0.048	80.9%	{"model__max_depth": null, "model__max_features": "sqrt", "model__min_samples_leaf": 5}
로지스틱 회귀	0.844 ± 0.047	79.2%	{"model__C": 1.0, "model__class_weight": "balanced"}
의사결정나무	0.840 ± 0.045	80.5%	{"model__max_depth": 5, "model__min_samples_leaf": 10}

CV AUC 옆의 ± 값은 다섯 폴드 간 표준편차다. 신뢰구간이 아니다. 설정 선택에도 사용한 점수이므로 독립적인 최종 성능 추정으로 해석하지 않는다. 선택 모델은 랜덤 포레스트다. 로지스틱 회귀는 `class_weight='balanced'`가 선택되어 두 결과 클래스의 학습 기여를 조절했다. 재현율 차이는 이번 설정과 자료에서의 결과이며 알고리즘의 보편적 특성으로 단정하지 않는다.

▼ Pipeline과 그룹 교차검증의 핵심 구조

```
from sklearn.model_selection import StratifiedGroupKFold, GridSearchCV
from titanic_models import features, pipeline_for

X = features(train)  # 7개 입력 선택과 행별 표기 정리만 수행
y = train['Survived']
groups = train['Ticket'].astype('string').str.strip().str.upper()

outer = StratifiedGroupKFold(n_splits=5, shuffle=True, random_state=42)
dev_idx, hold_idx = next(outer.split(X, y, groups))

inner = StratifiedGroupKFold(n_splits=5, shuffle=True, random_state=2026)
folds = list(inner.split(X.iloc[dev_idx], y.iloc[dev_idx], groups.iloc[dev_idx]))

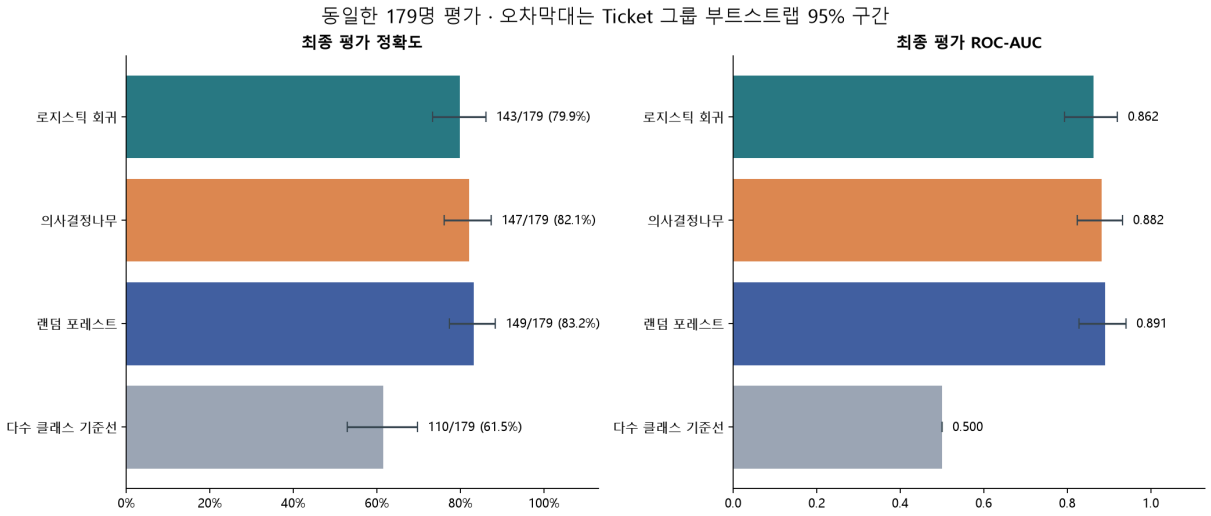
# 예: 실제 랜덤 포레스트와 동일한 탐색 범위
grid = {
    'model__max_depth': [5, 10, None],
    'model__min_samples_leaf': [1, 3, 5],
    'model__max_features': ['sqrt', 0.8],
}
search = GridSearchCV(
    pipeline_for('random_forest'), grid, cv=folds,
    scoring='roc_auc', refit=True, n_jobs=2, error_score='raise'
)
search.fit(X.iloc[dev_idx], y.iloc[dev_idx])
```

전체 코드는 세 모델과 여러 보조 지표를 함께 기록하고 평가 이전 선택을 저장한다. 모델 구성·전처리·분리·탐색 범위는 첨부 ZIP의 `titanic_models.py`와 `modeling-plan.json`에 있다.

10. 동일한 179명에서의 최종 예측 성능

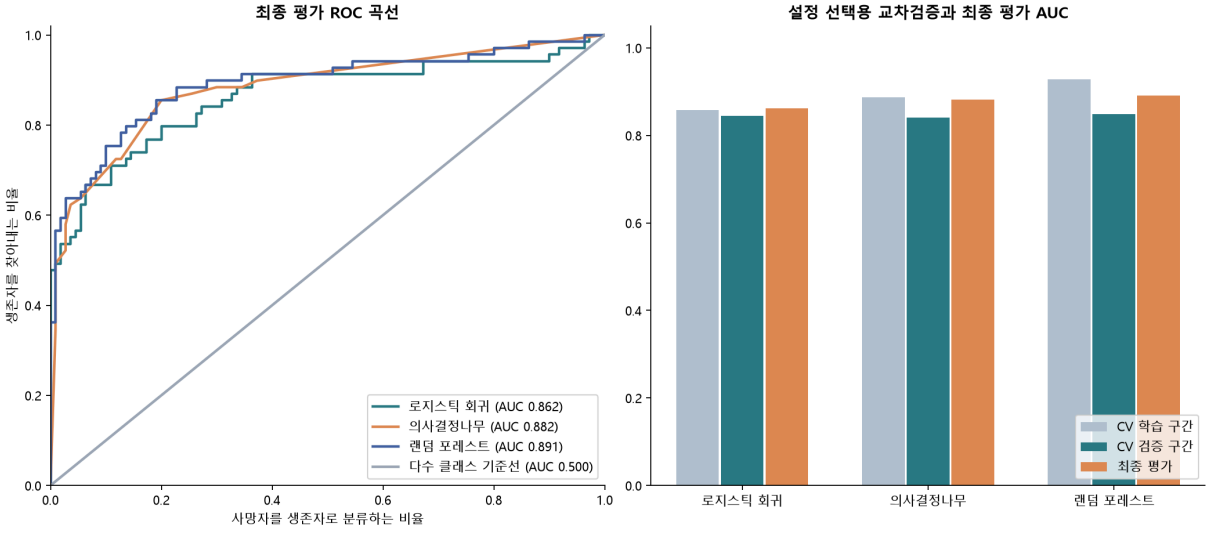
모든 모델의 평가 분류 기준은 **생존 확률 0.5 이상이면 생존**, 미만이면 사망이다. 평가 결과를 보고 이 기준을 바꾸지 않았다.

모델	정답/평가 인원	정확도	정밀도	생존자 재현율	F1	ROC-AUC
로지스틱 회귀	143/179	79.9%	72.6%	76.8%	0.746	0.862
의사결정나무	147/179	82.1%	79.4%	72.5%	0.758	0.882
랜덤 포레스트	149/179	83.2%	83.1%	71.0%	0.766	0.891
다수 클래스 기준선	110/179	61.5%	0.0%	0.0%	0.000	0.500



10.1 지표를 읽는 방법

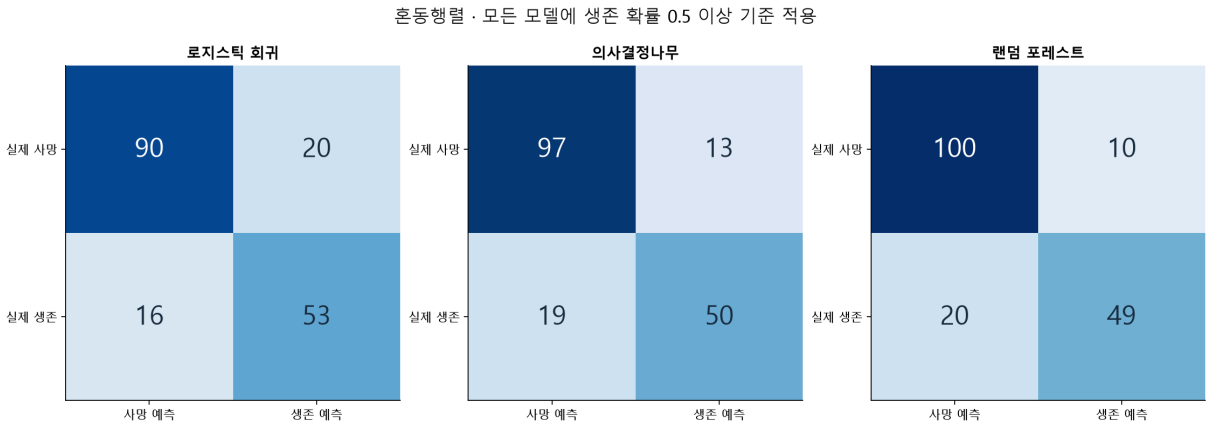
- 정확도: 전체 179명 중 생존/사망을 맞힌 비율.
- 정밀도: 생존이라고 예측한 사람 중 실제 생존한 비율.
- 생존자 재현율: 실제 생존자 69명 중 찾아낸 비율.
- F1: 생존자 정밀도와 재현율의 조화평균.
- ROC-AUC: 생존자를 사망자보다 높은 생존 확률로 정렬하는 능력. 0.5는 무작위 수준, 1은 완벽한 순위다. AUC 0.891을 정확도 89.1%라고 읽지 않는다.
- 추가 지표: 균형 정확도, Log loss, Brier도 CSV와 전체 보고서에 기록했다. Log loss·Brier는 낮을수록 좋다.



10.2 어떤 예측을 틀렸는가?

모델	사망을 사망으로(TN)	사망을 생존으로(FP)	생존을 사망으로(FN)	생존을 생존으로(TP)
로지스틱 회귀	90	20	16	53
의사결정나무	97	13	19	50

모델	사망을 사망으로(TN)	사망을 생존으로(FP)	생존을 사망으로(FN)	생존을 생존으로(TP)
랜덤 포레스트	100	10	20	49



랜덤 포레스트는 사망자 110명 중 100명, 생존자 69명 중 49명을 맞혔다. 로지스틱 회귀는 사망자 90명, 생존자 53명을 맞혔다. 따라서 이번 조건에서 전체 정확도는 랜덤 포레스트가 높지만 실제 생존자를 놓치지 않는 비율은 로지스틱 회귀가 높았다.

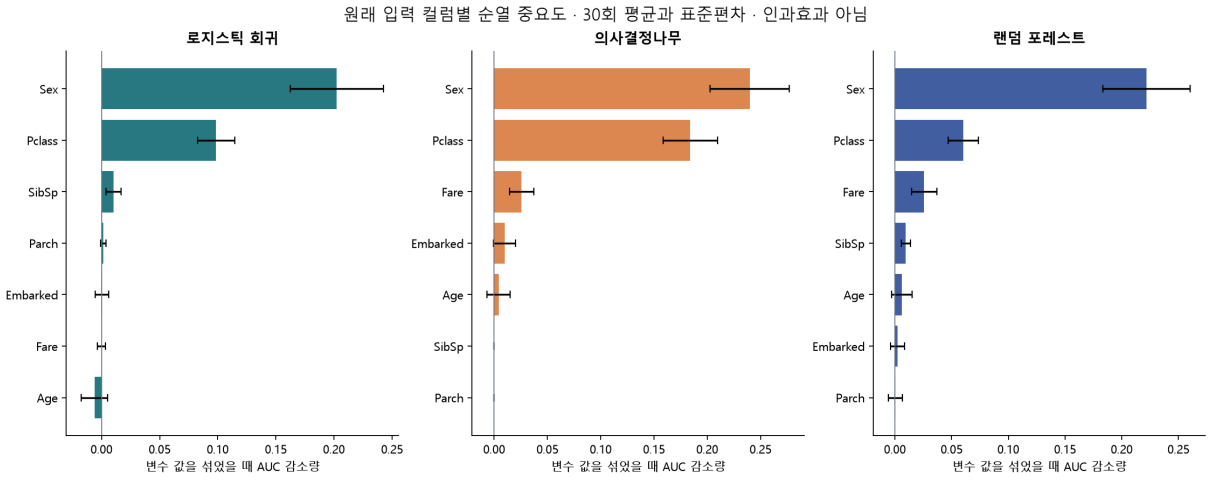
10.3 작은 성능 차이를 확실한 우열로 해석할 수 있는가?

비교: 랜덤 포레스트 – 상대 모델	지표	점수 차이	95% 구간
로지스틱 회귀	정확도(%p)	+3.35	[-1.80, +9.28]
로지스틱 회귀	ROC-AUC	+0.0286	[-0.0032, +0.0616]
의사결정나무	정확도(%p)	+1.12	[-1.84, +4.19]
의사결정나무	ROC-AUC	+0.0088	[-0.0139, +0.0344]

평가 구간의 같은 Ticket 승객을 묶어 2,000회 재표본화한 짝지은 차이 구간이다. 랜덤 포레스트는 의사결정나무보다 2명, 로지스틱 회귀보다 6명을 더 맞혔다. 하지만 세 모델 간 정확도·AUC 차이 구간은 0을 포함하므로 이 자료만으로 다른 조건에서도 확실히 우수하다고 단정하기 어렵다.

이 구간은 학습한 모델을 고정한 평가 승객의 재표본화 결과다. 다른 학습 자료·다른 분할·설정 탐색 전체를 반복한 불확실성은 포함하지 않고, 다중비교 보정 구간도 아니다.

11. 모델이 주로 사용한 정보와 의사결정나무 구조



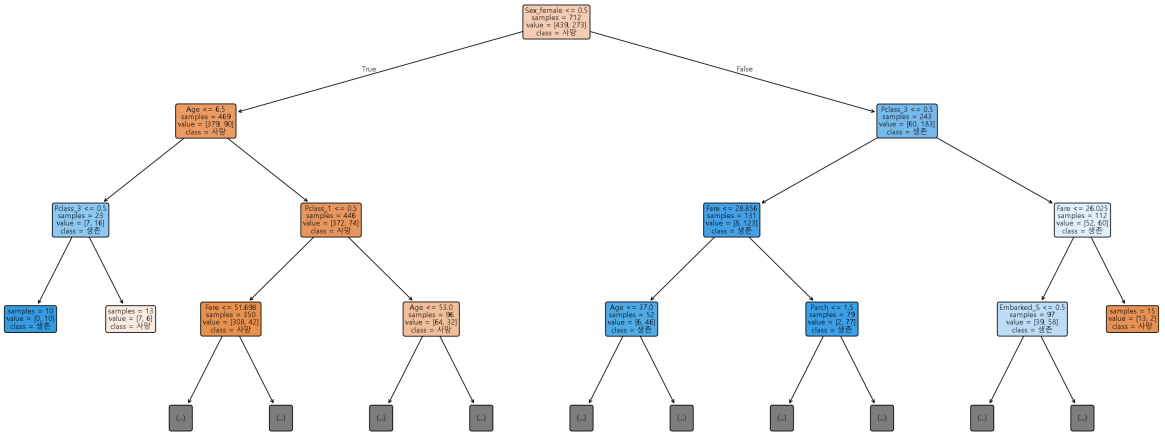
원래 입력 컬럼 하나의 값을 섞었을 때 평가 ROC-AUC가 얼마나 감소하는지 30회 반복했다. 평균 감소량이 높을수록 이번 모델이 이 자료에서 해당 정보를 많이 활용했다는 뜻이다.

입력 컬럼	랜덤 포레스트 AUC 감소량 평균	반복 간 표준편차
Sex	0.2218	0.0386

입력 컬럼	랜덤 포레스트 AUC 감소량 평균	반복 간 표준편차
Pclass	0.0602	0.0131
Fare	0.0258	0.0111
SibSp	0.0096	0.0040
Age	0.0060	0.0092
Embarked	0.0023	0.0062
Parch	0.0002	0.0062

세 모델 모두 Sex의 순열 중요도가 가장 컸다. 다만 중요도는 생존 원인의 크기나 인과효과가 아니며, 연관된 변수끼리는 정보가 겹칠 수 있다. 음수 또는 0에 가까운 중요도도 해당 변수가 역사적으로 의미 없다는 결론은 아니다. 중요도를 보고 모델을 다시 선택하거나 설정을 조정하지 않았다.

의사결정나무 상위 3단계 표시 · 실제 학습 깊이 5 · samples는 학습 승객 수



실제 단일 나무 깊이는 5이며 그림에는 상위 3단계를 표시했다. `Sex_female`, `Pclass_3` 같은 값은 원핫 인코딩 결과다. `samples`는 해당 노드의 학습 승객 수이고 `value`는 사망·생존 인원이다. 나무가 학습으로 선택한 Age≤6.5 같은 분기는 앞서 사람이 선택한 16세 가설 경계와 다른 종류의 기준이며, 다른 학습 자료에서는 바뀔 수 있다.

12. 전체 891명 재학습과 test.csv 418명 예측

평가를 마친 뒤 선택된 설정을 바꾸지 않고 각 모델을 전체 891명으로 다시 학습했다. 이 최종 모델로 test.csv 418명의 생존 확률과 예측값을 생성했다.

저장 파일	학습 대상·용도	해석
models/*_evaluated.joblib	개발용 712명 학습	위 179명 평가 결과의 대상 모델
models/*_final.joblib	전체 891명 재학습	새로운 승객·test.csv 예측용
predictions/holdout_predictions.csv	179명 실제 정답·예측 확률·예측값	성능 재계산 자료
predictions/test_predictions_all_models.csv	418명에 대한 세 모델 확률·예측	정답 없는 예측 비교
predictions/submission_selected.csv	CV 선택 모델의 PassengerId·Survived 2열	Kaggle 제출 형식, 업로드는 하지 않음

test.csv에 실제 정답이 없으므로 418명의 정확도·재현율은 계산하지 않는다. 위 성능은 평가용으로 남겨둔 179명의 결과다. 전체 학습 데이터를 다시 본 final 모델에 동일 평가 승객을 넣어 점수를 계산하면 독립 평가가 아니다.

13. 팀 공유용 전체 보고서·실행 자료

13.1 전체 재현 파일 ZIP

titanic_submission.zip

ZIP에는 코드·실행 노트북·환경 파일·기준 JSON·관찰 기록·집계표·차트·모델·418명 예측 파일이 들어 있다. 원본 train/test CSV, EDA 정제 개인별 CSV, 가상환경, 인증 정보는 제외했다. 원본 자료가 필요한 팀원은 위 출처에서 별도로 준비한다.

핵심 파일	내용
download_data.py	고정 커밋 사본 다운로드·독립 사본 값 대조·출처 기록
titanic_eda.py / titanic_eda.ipynb	정제·EDA·검정과 실제 실행 결과
analysis-plan.json	네 가설과 결측·검정 기준
titanic-observations.md	강의 제출 항목에 맞춘 관찰 기록
titanic_models.py / titanic_models.ipynb	모델 학습·비교·저장 모델 재평가
model_report.py	모델 비교 보고서와 차트 생성
modeling-plan.json	분리 방식·입력·설정 탐색·선택 기준
predict_survival.py	저장한 최종 모델을 불러와 새 CSV 예측
requirements.txt / environment.yml	실제 실행 버전에 맞춘 환경
output/verification.json, output/modeling/verification.json	원본·집계·모델·예측 재현 검증 기록

13.2 정제·EDA·가설 검정 전체 보고서

attachment:a9552579-e50f-43d1-a1ba-75c7f2342dc3:titanic_report.html

13.3 예측 모델 전체 비교 보고서

attachment:ea8adf76-95a6-47c3-85d7-4dfdf0991ddc:model_comparison.html

13.4 재실행 순서

프로젝트 원본 폴더는 작성자 PC의 `D:\BigData\0_Titanic`이다. 이 경로는 공유 다운로드 링크가 아니므로 팀원은 ZIP을 자기 작업 폴더에 풀고 상대 경로 기준으로 실행한다. Python 3.12를 기준으로 환경을 만들었다.

▼ Python 가상환경으로 실행

```
# ZIP을 푼 프로젝트 폴더에서 실행
py -3.12 -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt

# 원본 CSV가 없다면 공개 사본을 다운로드하고 대조
# 기존 원본이 있으면 덮어쓰지 않도록 오류를 내므로 이 단계는 생략
.\.venv\Scripts\python.exe download_data.py

# 정제·EDA·가설 검정
.\.venv\Scripts\python.exe titanic_eda.py

# 세 모델의 전체 학습·비교·최종 예측
.\.venv\Scripts\python.exe titanic_models.py

# 학습 없이 저장한 선택 모델로 예측만 다시 생성
.\.venv\Scripts\python.exe predict_survival.py
```

노트북은 프로젝트의 `.venv` Python을 선택해 연다. 모델 노트북은 기본적으로 저장 모델을 다시 불러와 재평가한다. 전체 재학습은 마지막 셀의 RETRAIN=True 또는 위 명령으로 수행한다.

▼ Conda로 실행

```
conda env create -f environment.yml
conda activate titanic-eda
```

```
python titanic_eda.py
python titanic_models.py
```

environment.yml은 이번 분석용으로 작성한 파일이다. 접근할 수 없었던 강의 서버 파일을 직접 내려받았다고 표시하지 않았다.

14. 검증 기록과 발표 시 표현 기준

14.1 실제로 확인한 검증

- 원본 파일의 다운로드 당시 체크섬과 분석 후 체크섬 일치.
- 정제 후 보존된 승객과 제외 승객 ID가 원본을 중복 없이 분할하는지 확인.
- 제외 사유를 원본의 빈칸에서 독립적으로 다시 계산해 대조.
- EDA에서 수치 결측을 임의 대체하지 않았고 미상 나이를 성인으로 넣지 않았는지 확인.
- 성별×등급별 인원·생존자와 전체 342/891명의 합계 대조.
- Holm 보정과 비율차 산술을 별도로 검증.
- 모델의 최종 평가·교차검증에서 동일 Ticket 중복 0개 확인.
- 혼동행렬·정확도·정밀도·재현율·F1을 예측 파일의 인원에서 다시 계산.
- ROC-AUC를 생존자·사망자 확률 쌍으로 별도 계산해 대조.
- 저장한 evaluated/final 모델 6개를 다시 불러와 179명 평가와 418명 예측 재현.
- EDA 노트북과 모델 노트북의 실행 오류가 없는지 확인.
- 차트 8개를 시각적으로 확인하고 두 HTML 보고서에 포함.

14.2 표현을 구분한다

사용할 표현	해당 표현만으로 주장할 수 없는 것
여성 생존율이 남성보다 55.3%p 높게 관찰됐다	여성이라는 특성이 단독 원인이라는 결론
등급과 생존 여부의 연관이 통계적으로 관찰됐다	요금이나 부가 생존을 직접 일으켰다는 결론
16세 미만/이상 비교에서 차이가 났다	교수님·역사·법률이 정한 어린이 기준이라는 주장
기록된 가족 동행 집단의 생존율이 높았다	모든 가족 규모에서 같은 효과, 실제 혼자 여행 여부
랜덤 포레스트가 이번 179명에서 정확도 83.2%였다	Kaggle test 정확도 83.2%, 어느 자료에서나 최고라는 주장
성별 순열 중요도가 높았다	성별의 인과효과·정책 준수 정도를 측정했다는 주장
팀 질문 10개 분석 완료: 6개 대표 H0 기각·4개 근거 부족	질문 10개의 모든 가설이 맞다고 검증됐다는 주장

이 자료는 비무작위 역사 자료의 교육용 탐색이다. 같은 Ticket은 모델 분할에서 묶었지만 서로 다른 Ticket의 가족까지 완전히 묶지는 않았다. 데이터는 앞선 EDA에서도 살펴봤으므로 완전히 새로운 외부 자료에 대한 전향적 검증과 같지 않다. 이번 입력·분리·설정 탐색 범위의 비교 결과로 읽는다.

15. 출처와 관련 자료

- 원출처·변수 설명: Kaggle Titanic.
- 실제 사용 사본·독립 대조 주소·체크섬: 2절 표 및 첨부 ZIP의 data/raw/download_manifest.json.
- 검정 방법: SciPy Fisher 정확 검정, 카이제곱 독립성 검정, statsmodels 다중검정 보정.
- 모델 평가: scikit-learn 정보 누출·Pipeline, StratifiedGroupKFold, 순열 중요도.
- 역사적 맥락: 미국 상원 타이타닉 조사보고서 전사본. CSV 분석 결과와 별도 출처로 구분했다.
- 관련 수업·팀 활동 자료: . 이 페이지의 수치와 코드는 이번 프로젝트의 실제 실행 결과를 기준으로 정리했다.

16. 팀 질문 Q1~Q10 실제 분석 결과·그래프

추가 정리일: @2026년 10월 27일

✅ **설계한 팀 질문 10개를 모두 실제로 분석했다.** 아래에는 질문별 모집단·대표 귀무가정·검정 방법·효과 수치·그래프·판정·해석 한계를 제시한다. 분석 완료는 10개 가설이 모두 맞았다는 뜻이 아니다. 대표 검정 10개를 Holm 보정한 뒤 Q1·Q2·Q3·Q4·Q5·Q9는 귀무가설을 기각했고, Q6·Q7·Q8·Q10은 근거가 충분하지 않았다.
Q1에서는 여섯 집단 모두 음의 상관이므로 "나이가 많을수록 기록 요금이 높다"는 방향을 지지한 것이 아니다. 차이를 확인하지 못한 질문도 같다는 증명으로 읽지 않는다.

기존 내용과의 관계: 8절은 최초 질문 설계 기록이고, 이 16절이 해당 질문의 실제 실행 결과다. 앞의 가설 4개와 예측 모델 비교는 기존 결과를 보존했다. 원본 파일도 수정하지 않았다.

공통 분석 기준과 표 읽는 방법

- Q1~Q9는 train.csv 891명, Q10은 train/test 총 1309명이다. Q1·Q4는 나이 결측 177명 제외, Q6은 항구 결측 2명 제외다. Q7은 나이 결측 자체를 분석하므로 누락 승객도 포함한다.
- 질문당 대표 검정 하나씩 **총 10개 p값을 Holm 보정**했다. 유의수준은 0.05다. 세부 집단마다 추가 p값을 나열한 것이 아니다.
- 순열 검정은 10,000회이며 `(관측값 이상인 귀무 통계량 횟수+1)/10001`로 계산했다. 최소 가능한 몬테카를로 p값은 약 0.0001이며 0이라고 쓰지 않는다.
- Q1·Q2는 성별×등급 6개 집단의 스피어만 상관 제곱을 인원 가중해 합친 대표 통계량을 사용했다. 요금 순위를 각 층 안에서 섞었다.
- Q3·Q4·Q8은 각 층의 중앙값 차이를 전체 IQR(사분위 범위)로 나눈 값의 제곱을 인원 가중해 합쳤다. 대표 순열 검정의 귀무가정은 층 안의 두 분포가 교환 가능하다는 것이다. 분포 모양은 달라도 중앙값만 같다는 약한 귀무가설의 별도 검정으로 부르지 않는다.
- Q5·Q7은 같은 Ticket 승객을 군집으로 고려한 강건 공분산과 Wald 검정으로 **집단별 생존율 차이가 같은지** 검사했다. 이를 위한 포화 선형확률식은 추론용 계산이며, 기존 로지스틱 회귀·의사결정나무·랜덤 포레스트의 성능을 다시 평가하거나 바꾼 작업이 아니다.
- Q6은 희소한 항구 셀이 있어 점근 카이제곱 p값 대신, 층별 Pearson 통계량 합을 조건부 순열로 평가했다.
- Q9는 원래 약속한 성별×등급 안의 10,000회 결과 섞기를 그대로 수행했다. Q10은 두 수치 중앙값 차이의 IQR 표준화 제곱과 두 결측률 차이 제곱을 인원 가중해 합쳐 평가했다. 파일 라벨은 행 전체 단위로 바꿨다.
- **순열 검정의 한계:** 승객 라벨은 각 층 안에서 교환 가능하다고 가정한다. Ticket 집단을 통째로 유지해 섞은 검정은 아니므로 가족 내 의존성을 모두 반영한 p값이 아니다. 탐색적 교육용 참고값으로 해석한다.
- **구간의 한계:** Q3·Q4·Q8·Q10은 Ticket 그룹 2,000회 재표본화 구간이다. 비교 집단이 사라진 재표본은 제외하고 유효 횟수를 기록했다. Q5·Q7의 개별 비율차는 독립 이항 표본 가정의 Newcombe 구간이다. 구간은 모두 개별 비보정 구간이며, 1~2명 집단의 정보 부족을 해결하지 못한다.

결과 요약

질문	분석 모집단 n	Holm 보정 p	대표 H0 판정	관찰 결과
Q1	714	0.0008999	기각	6개 집단 모두 음의 상관: ρ 약 −0.039~−0.275
Q2	891	0.0008999	기각	6개 집단 모두 양의 상관: ρ 약 +0.167~+0.879
Q3	891	0.0008999	기각	여성-남성 요금 중앙값 차이: 1등급 +41.40, 2등급 +9.00, 3등급 +4.55파운드
Q4	714	0.0008999	기각	나이 중앙값 차이는 집단마다 다름. 남성 2등급 −27.5세이나 구간·인원 주의
Q5	891	2.506e-06	기각	성별 생존율 차이 최대 2등급 76.36%p, 최소 3등급 36.46%p
Q6	889	0.1968	기각 근거 부족	공통 성별·등급 구성 비교의 대표 검정에서 근거 부족. Q 항구 희소 셀 주의
Q7	891	0.1478	기각 근거 부족	원 p=0.0369이나 보정 후 0.1478. 결측 차이의 이질성을 뚜렷하게 확인 못함
Q8	891	0.2844	기각 근거 부족	객실 기록 쪽 요금이 항상 높지 않음. 보정 후 대표 검정 근거 부족
Q9	891	0.0008999	기각	동일 승선권 쌍 일치율 76.07%, 조건부 무작위 기준 평균 57.89%
Q10	1309	0.2844	기각 근거 부족	일부 점 추정 차이는 있으나 중앙값·결측률 대표 검정의 근거 부족

16.1. Q1 — 같은 성별·등급에서 나이가 많을수록 기록 요금도 높은가?

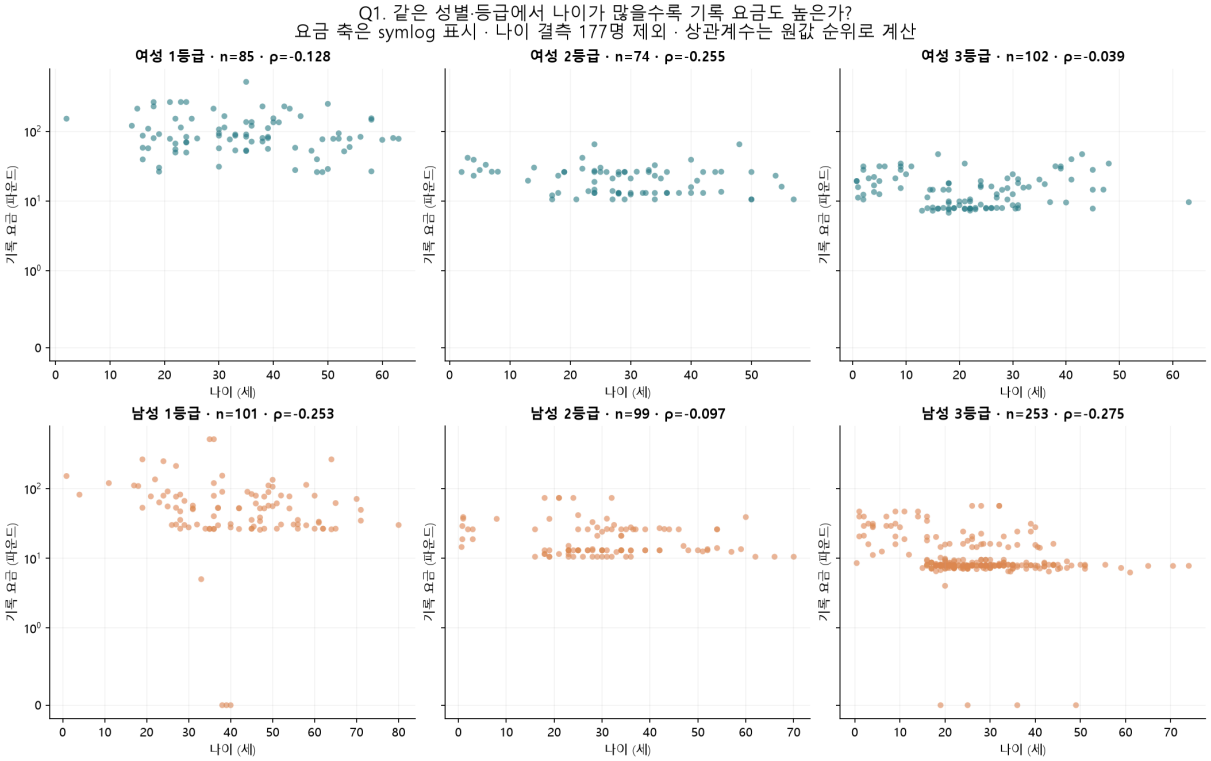
대상: 714명, 질문별 제외 177명.

대표 귀무가정: 성별·등급 안에서 나이와 요금 순위가 무관하여 요금 순위를 교환할 수 있다.

방법: 층별 스피어만 상관 제곱의 인원 가중 합, 층 내 10000회 순열

판정: 원 p=9.999e-05, Holm 보정 p=0.0008999. 대표 귀무가설 기각.

성별·등급	분석 인원	스피어만 ρ
여성 1등급	85	-0.128
여성 2등급	74	-0.255
여성 3등급	102	-0.039
남성 1등급	101	-0.253
남성 2등급	99	-0.097
남성 3등급	253	-0.275



관찰 결과

- 여섯 집단 모두 상관계수가 음수다. 따라서 이 자료는 '나이가 많을수록 요금이 높다'는 방향을 보여주지 않았다.
- 상관의 절댓값이 가장 큰 집단은 남성 3등급(n=253, ρ=-0.275)이다. 대체로 약한 음의 단조 연관이다.
- 대표 검정은 성별·등급 안에서 나이와 요금 순위가 무관하게 교환 가능하다는 가정을 평가했다. 유의하다는 판정이 여섯 개 각각의 유의성을 뜻하지 않는다.

해석 범위·주의할 점

- Age 결측 177명 제외. 선택된 관측 나이 집단의 결과이며 나이가 요금을 변화시킨다는 인과효과가 아니다.

16.2. Q2 — 같은 성별·등급에서 가족 규모가 클수록 기록 요금도 높은가?

대상: 891명, 질문별 제외 0명.

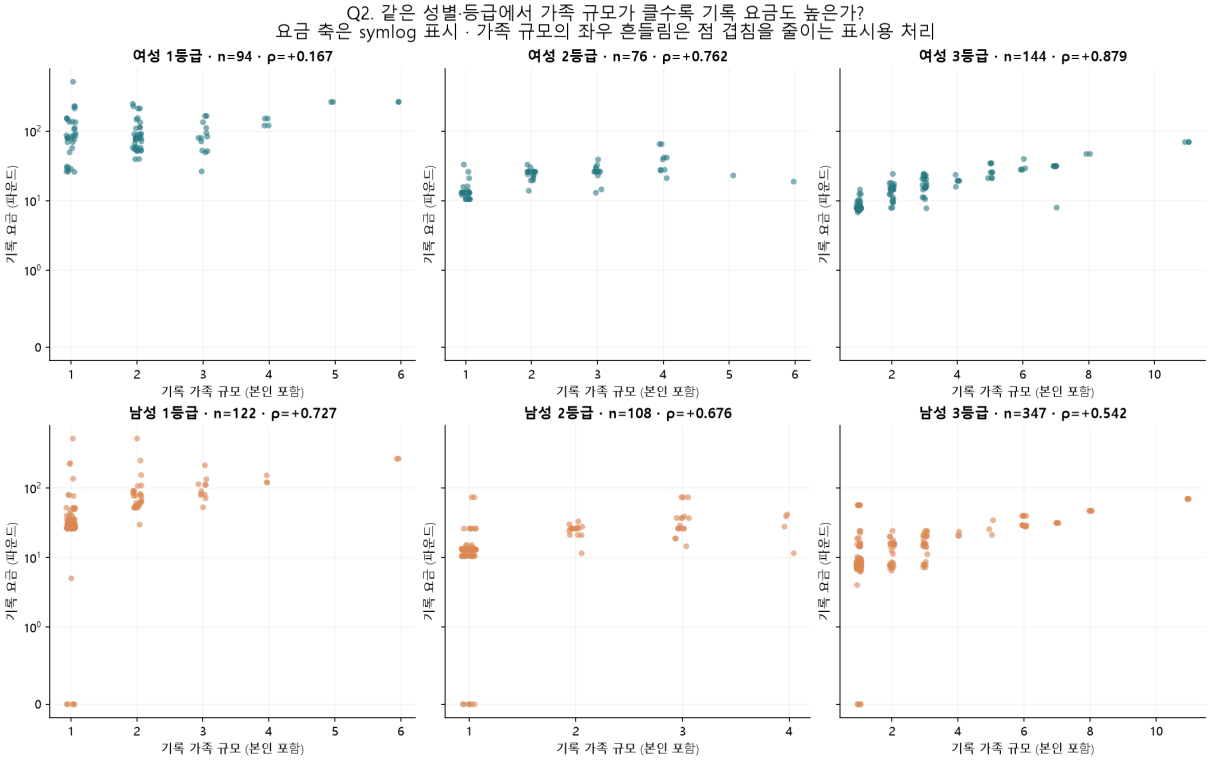
대표 귀무가정: 성별·등급 안에서 기록 가족 규모와 요금 순위가 무관하여 요금 순위를 교환할 수 있다.

방법: 층별 스피어만 상관 제곱의 인원 가중 합, 층 내 10000회 순열

판정: 원 p=9.999e-05, Holm 보정 p=0.0008999. 대표 귀무가설 기각.

성별·등급	분석 인원	스피어만 ρ
여성 1등급	94	+0.167
여성 2등급	76	+0.762
여성 3등급	144	+0.879

성별·등급	분석 인원	스피어만 ρ
남성 1등급	122	+0.727
남성 2등급	108	+0.676
남성 3등급	347	+0.542



관찰 결과

- 여섯 집단 모두 가족 규모와 기록 요금의 상관이 양수다.
- 가장 강한 집단은 여성 3등급(n=144, ρ=+0.879)이다. 여성 1등급은 ρ=+0.167로 상대적으로 약하다.
- 성별·등급·실제 FamilySize별 요금 중앙값과 인원은 Q2_family_medians.csv에 함께 저장했다.

해석 범위·주의할 점

- Fare는 기록된 승선권 요금이며 개인별 지출액으로 확정할 수 없다. 동행 가족·공유 승선권의 같은 요금 기록 때문에 관계가 나타날 수 있다.

16.3. Q3 — 같은 등급에서 여성–남성 요금 중앙값은 몇 파운드 차이 나는가?

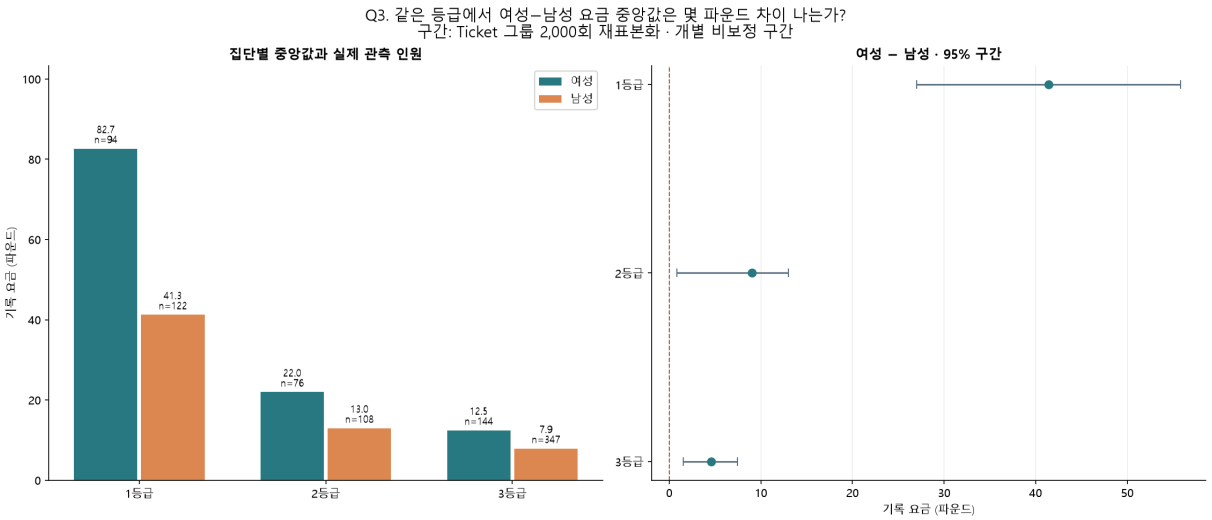
대상: 891명, 질문별 제외 0명.

대표 귀무가정: 등급 안의 여성·남성 요금 분포가 교환 가능하다. 중앙값만 같은 약한 귀무가설과 구분한다.

방법: IQR 표준화 층별 중앙값 차이 제곱의 가중 합, 층 내 10000회 순열

판정: 원 p=9.999e-05, Holm 보정 p=0.0008999. 대표 귀무가설 기각.

집단	여성 n	남성 n	여성 중앙값	남성 중앙값	차이(파운드)	95% 구간	유효 재표본/2000
1등급	94	122	82.66	41.26	+41.40	[+27.02, +55.80]	2000
2등급	76	108	22.00	13.00	+9.00	[+0.82, +13.00]	2000
3등급	144	347	12.47	7.92	+4.55	[+1.54, +7.45]	2000



관찰 결과

- 세 등급 모두 여성의 요금 중앙값이 남성보다 높다.
- 여성–남성 중앙값 차이는 1등급 +41.40파운드, 2등급 +9.00파운드, 3등급 +4.55파운드다.

해석 범위·주의할 점

- 개별 중앙값 차이는 기술적 효과 요약이다. 순열 검정의 귀무가정은 등급 안의 두 요금 분포가 교환 가능하다는 것이며, 분포 모양이 달라도 중앙값만 같다는 약한 귀무가설을 별도로 검정한 것은 아니다.
- 구간은 각 층의 Ticket 그룹 2000회 재표본화 백분위 구간이다. 비교 집단이 사라진 재표본은 제외했고 유효 횟수를 표시했다. 개별 구간은 다중비교 비보정이다.

16.4. Q4 — 같은 성별·등급에서 생존자–사망자 나이 중앙값은 몇 세 차이 나는가?

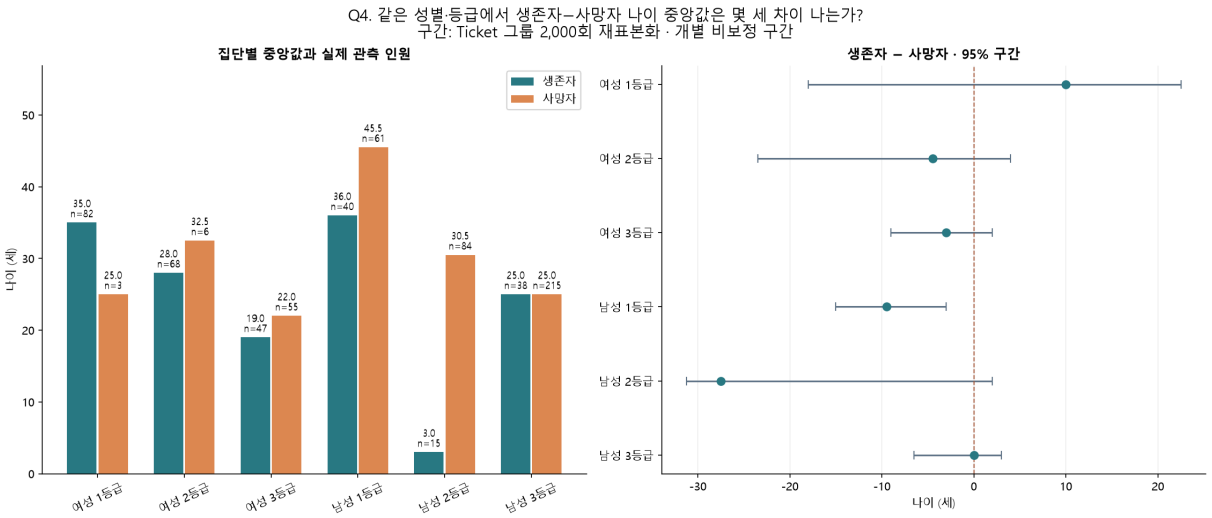
대상: 714명, 질문별 제외 177명.

대표 귀무가정: 성별·등급 안의 생존자·사망자 나이 분포가 교환 가능하다. 중앙값만 같은 약한 귀무가설과 구분한다.

방법: IQR 표준화 층별 중앙값 차이 제곱의 가중 합, 층 내 10000회 순열

판정: 원 p=9.999e-05, Holm 보정 p=0.0008999. 대표 귀무가설 기각.

집단	생존자 n	사망자 n	생존자 중앙값	사망자 중앙값	차이(세)	95% 구간	유효 재표본/2000
여성 1등급	82	3	35.00	25.00	+10.00	[-18.00, +22.50]	1738
여성 2등급	68	6	28.00	32.50	-4.50	[-23.50, +4.00]	1994
여성 3등급	47	55	19.00	22.00	-3.00	[-9.00, +2.00]	2000
남성 1등급	40	61	36.00	45.50	-9.50	[-15.00, -3.00]	2000
남성 2등급	15	84	3.00	30.50	-27.50	[-31.25, +2.00]	2000
남성 3등급	38	215	25.00	25.00	+0.00	[-6.50, +3.00]	2000



관찰 결과

- 남성 2등급의 생존자 나이 중앙값은 3.0세(n=15), 사망자는 30.5세(n=84)로 관측 차이가 −27.5세다.
- 반면 여성 1등급은 생존자 35세, 사망자 25세로 +10세이고, 남성 3등급은 두 중앙값 모두 25세다. 모든 집단에서 동일한 방향은 아니다.

해석 범위·주의할 점

- 여성 1등급의 나이가 알려진 사망자는 3명뿐이다. 2000회 그룹 재표본 중 양쪽 결과 집단이 모두 남은 것은 1738회이며 구간도 불안정하다.
- 대표 순열 검정과 Ticket 그룹 부트스트랩 구간은 가정이 다르다. 남성 2등급의 개별 구간도 0을 포함하므로 큰 점 추정만으로 안정적인 개별 차이라고 단정하지 않는다.
- 구간은 각 층의 Ticket 그룹 2000회 재표본화 백분위 구간이다. 비교 집단이 사라진 재표본은 제외했고 유효 횟수를 표시했다. 개별 구간은 다중비교 비보정이다.

16.5. Q5 — 여성–남성 생존율 차이의 크기는 등급마다 다른가?

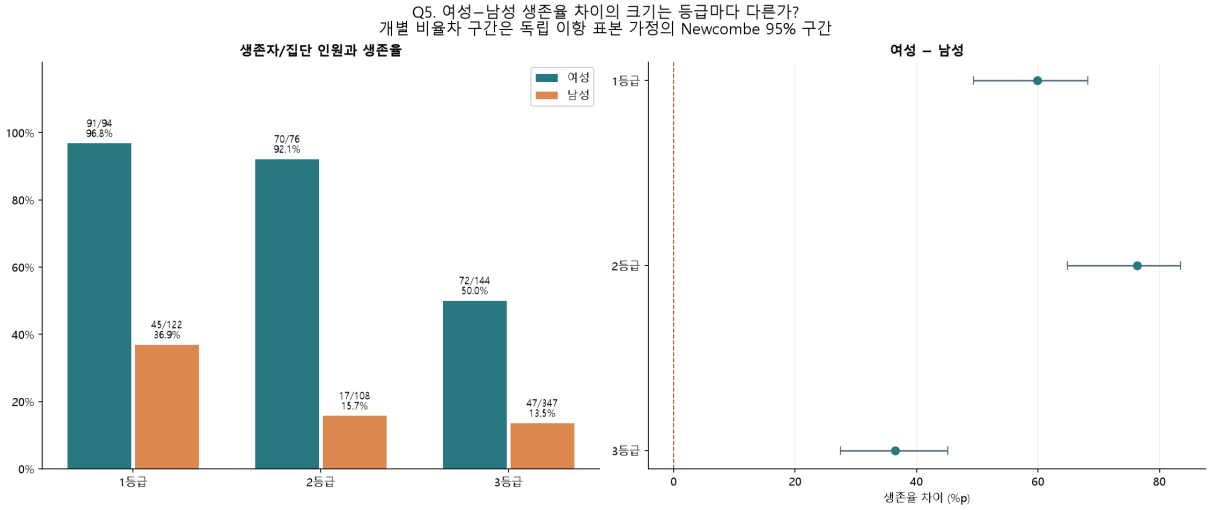
대상: 891명, 질문별 제외 0명.

대표 귀무가정: 1·2·3등급의 여성–남성 생존율 차이 세 개가 같다.

방법: Ticket 군집 강건 포화 선형확률모형, 비율차 동일성 Wald 검정

판정: 원 p=2.506e-07, Holm 보정 p=2.506e-06. 대표 귀무가설 기각.

집단	여성 생존/인원	남성 생존/인원	여성 생존율	남성 생존율	차이(%p)	개별 95% 구간
1등급	91/94	45/122	96.8%	36.9%	+59.92	[+49.36, +68.23]
2등급	70/76	17/108	92.1%	15.7%	+76.36	[+64.83, +83.44]
3등급	72/144	47/347	50.0%	13.5%	+36.46	[+27.46, +45.13]



관찰 결과

- 여성–남성 생존율 차이는 1등급 59.92%p, 2등급 76.36%p, 3등급 36.46%p다. 가장 큰 차이는 2등급이다.
- 이번 검정은 성별 차이가 0인지가 아니라 세 등급의 성별 차이 크기가 같은지를 검사했다. Ticket 군집 강건 Wald 검정으로 차이의 이질성이 관찰됐다.

해석 범위·주의할 점

- 나이·요금·대피 상황까지 통제한 인과효과는 아니다. 이 결과로 구조 정책의 준수 정도를 측정했다고 표현하지 않는다.
- 대표 검정은 Ticket 군집 강건 공분산을 사용한다. 그림의 개별 비율차 구간은 독립 이항 표본 가정의 비보정 Newcombe 구간으로, 대표 검정과 구분한다.

16.6. Q6 — 같은 성별·등급에서도 항구 C·Q·S에 따라 생존율이 다른가?

대상: 889명, 질문별 제외 2명.

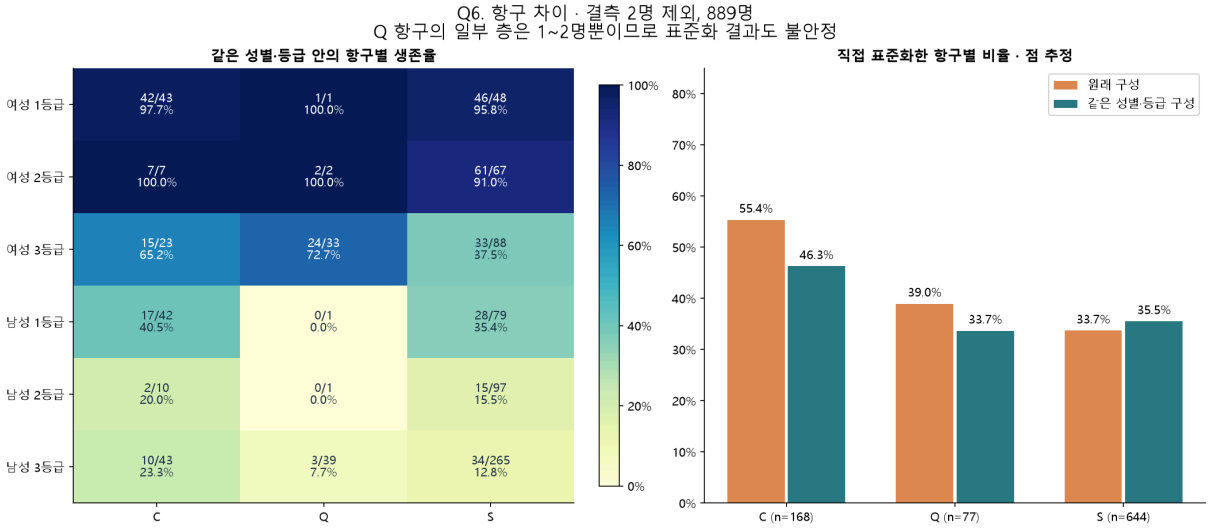
대표 귀무가정: 성별·등급 안에서 항구와 생존 여부가 무관하여 생존 라벨을 교환할 수 있다.

방법: 층별 Pearson 통계량 합, Sex×Pclass 안의 생존 라벨 10000회 순열

판정: 원 p=0.06559, Holm 보정 p=0.1968. 대표 귀무가설을 기각할 근거 부족.

성별·등급	항구	생존자/인원	생존율
여성 1등급	C	42/43	97.7%
여성 1등급	Q	1/1	100.0%
여성 1등급	S	46/48	95.8%
여성 2등급	C	7/7	100.0%
여성 2등급	Q	2/2	100.0%
여성 2등급	S	61/67	91.0%
여성 3등급	C	15/23	65.2%
여성 3등급	Q	24/33	72.7%
여성 3등급	S	33/88	37.5%
남성 1등급	C	17/42	40.5%
남성 1등급	Q	0/1	0.0%
남성 1등급	S	28/79	35.4%
남성 2등급	C	2/10	20.0%
남성 2등급	Q	0/1	0.0%
남성 2등급	S	15/97	15.5%
남성 3등급	C	10/43	23.3%
남성 3등급	Q	3/39	7.7%
남성 3등급	S	34/265	12.8%

항구	인원	원래 생존율	같은 성별·등급 구성의 표준화 생존율
C	168	55.4%	46.3%
Q	77	39.0%	33.7%
S	644	33.7%	35.5%



관찰 결과

- C 항구의 원래 생존율은 55.4%지만 같은 성별·등급 구성으로 맞춘 점 추정은 46.3%다. Q는 39.0%→33.7%, S는 33.7%→35.5%다.
- 희소 셀을 반영한 조건부 순열 검정의 원 p값은 0.0656, 보정 p값은 0.1968다. 대표 검정에서는 뚜렷한 조건부 연관을 확인하지 못했다.

해석 범위·주의할 점

- Q 항구 여성 1등급 1명, 여성 2등급 2명, 남성 1등급 1명, 남성 2등급 1명이다. 표준화 점 추정도 이 작은 셀에 의존하며 안정적인 항구 순위가 아니다.
- 항구 간 층별 비율차는 Q6_port_differences.csv에 저장했다. 별도 모든 항구 쌍의 유의성 검정을 한 것은 아니다. Embarked 결측 2명 제외, 889명 분석.

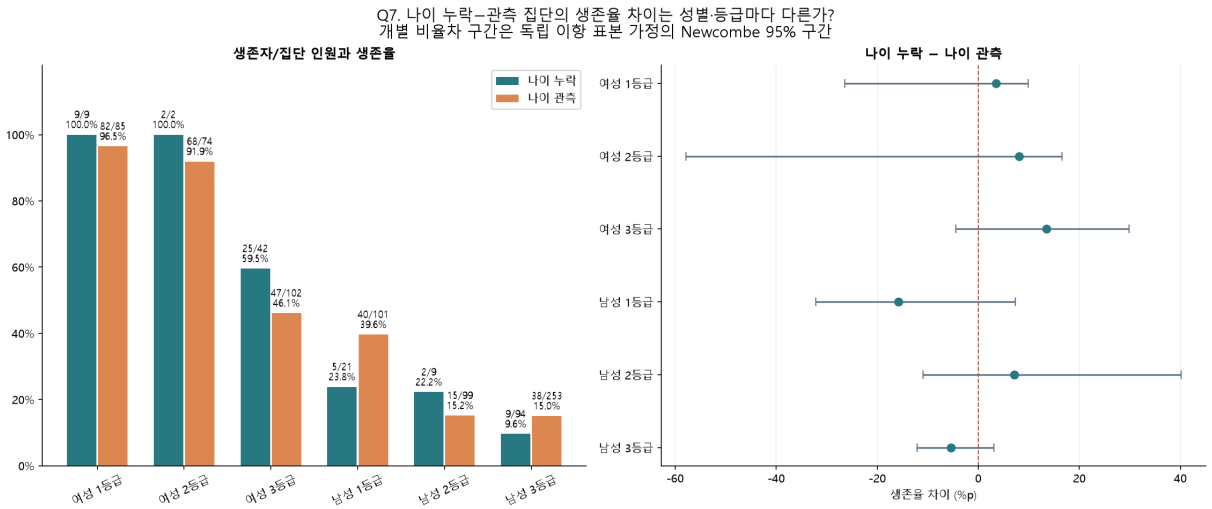
16.7. Q7 — 나이 누락–관측 집단의 생존율 차이는 성별·등급마다 다른가?

대표 귀무가정: 성별·등급 6개 집단의 나이 누락–관측 생존율 차이가 모두 같다.

방법: Ticket 군집 강건 포화 선형확률모형, 비율차 동일성 Wald 검정

판정: 원 p=0.03694, Holm 보정 p=0.1478. 대표 귀무가설을 기각할 근거 부족.

집단	나이 누락 생존/인원	나이 관측 생존/인원	나이 누락 생존율	나이 관측 생존율	차이(%p)	개별 95% 구간
여성 1등급	9/9	82/85	100.0%	96.5%	+3.53	[-26.48, +9.87]
여성 2등급	2/2	68/74	100.0%	91.9%	+8.11	[-57.80, +16.58]
여성 3등급	25/42	47/102	59.5%	46.1%	+13.45	[-4.41, +29.82]
남성 1등급	5/21	40/101	23.8%	39.6%	-15.79	[-32.19, +7.31]
남성 2등급	2/9	15/99	22.2%	15.2%	+7.07	[-10.89, +40.09]
남성 3등급	9/94	38/253	9.6%	15.0%	-5.45	[-12.09, +3.11]



관찰 결과

- 누락–관측 생존율 차이는 여성 3등급 +13.45%p, 남성 1등급 −15.79%p 등 집단별 방향이 다르다.
- 원 p값은 0.0369지만 10개 질문 Holm 보정 후 0.1478다. 이질성의 근거가 충분하지 않았다.

해석 범위·주의할 점

- 여성 2등급 나이 누락 집단은 2명 모두 생존했다. 이런 희소 셀에서 군집 강건 검정의 큰 표본 근사가 불안정할 수 있다.
- 기각하지 못했다는 사실은 결측이 무작위라는 증명, 결측 제거가 안전하다는 증명, 모든 집단의 차이가 같다는 증명이 아니다.
- 대표 검정은 Ticket 군집 강건 공분산을 사용한다. 그림의 개별 비율차 구간은 독립 이항 표본 가정의 비보정 Newcombe 구간으로, 대표 검정과 구분한다.

16.8. Q8 — 같은 성별·등급에서 객실 기록 유무에 따라 요금 중앙값이 다른가?

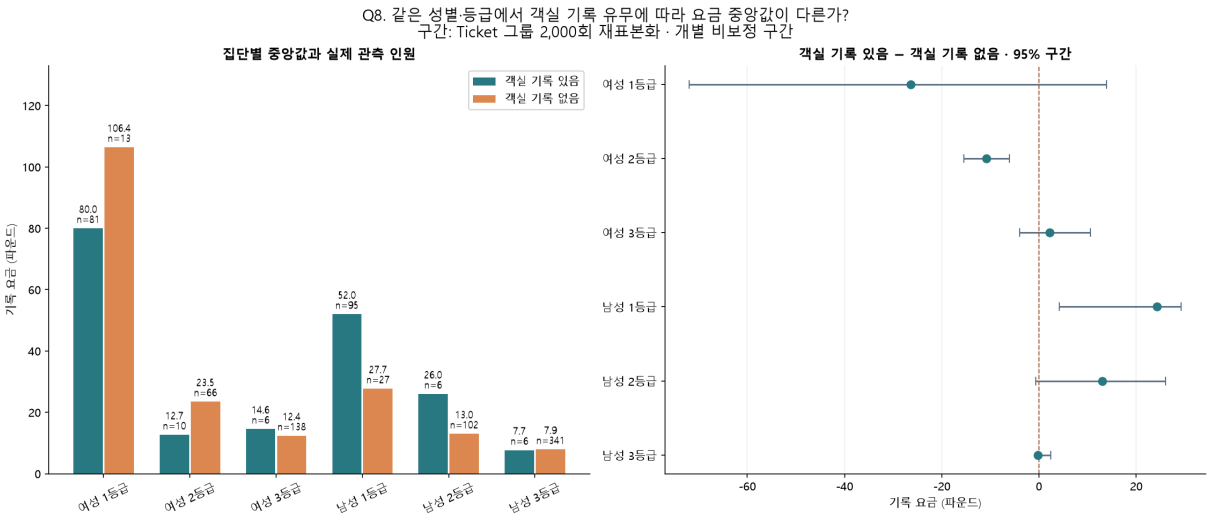
대상: 891명, 질문별 제외 0명.

대표 귀무가정: 성별·등급 안의 Cabin 기록 있음·없음 요금 분포가 교환 가능하다.

방법: IQR 표준화 층별 중앙값 차이 제곱의 가중 합, 층 내 10000회 순열

판정: 원 p=0.2064, Holm 보정 p=0.2844. 대표 귀무가설을 기각할 근거 부족.

집단	객실 기록 있음 n	객실 기록 없음 n	객실 기록 있음 중앙값	객실 기록 없음 중앙값	차이(파운드)	95% 구간	유효 재표본/2000
여성 1등급	81	13	80.00	106.42	-26.43	[-71.90, +13.86]	2000
여성 2등급	10	66	12.68	23.50	-10.82	[-15.50, -6.12]	2000
여성 3등급	6	138	14.59	12.38	+2.21	[-3.99, +10.57]	1955
남성 1등급	95	27	52.00	27.72	+24.28	[+4.15, +29.21]	2000
남성 2등급	6	102	26.00	13.00	+13.00	[-0.62, +26.00]	1968
남성 3등급	6	341	7.70	7.92	-0.23	[-0.40, +2.37]	1998



관찰 결과

- Cabin 기록이 있는 쪽의 요금이 항상 높은 것은 아니다. 여성 1등급 −26.43파운드, 남성 1등급 +24.28파운드로 방향도 다르다.
- 10개 대표 검정 보정 후, 이 대표 통계량으로 전체적인 조건부 요금 차이를 뚜렷하게 확인하지 못했다.

해석 범위·주의할 점

- 객실 기록이 있는 여성 3등급·남성 2등급·남성 3등급은 각각 6명뿐이다. Cabin 기록 유무는 실제 객실 보유 여부가 아니다.
- 일부 비보정 구간이 0을 포함하지 않더라도 다중검정을 거친 대표 검정을 대신하는 개별 유의성 결론으로 사용하지 않는다.
- 구간은 각 층의 Ticket 그룹 2000회 재표본화 백분위 구간이다. 비교 집단이 사라진 재표본은 제외했고 유효 횟수를 표시했다. 개별 구간은 다중비교 비보정이다.

16.9. Q9 — 동일 승선권 승객의 생존 결과는 조건부 무작위 기준보다 비슷한가?

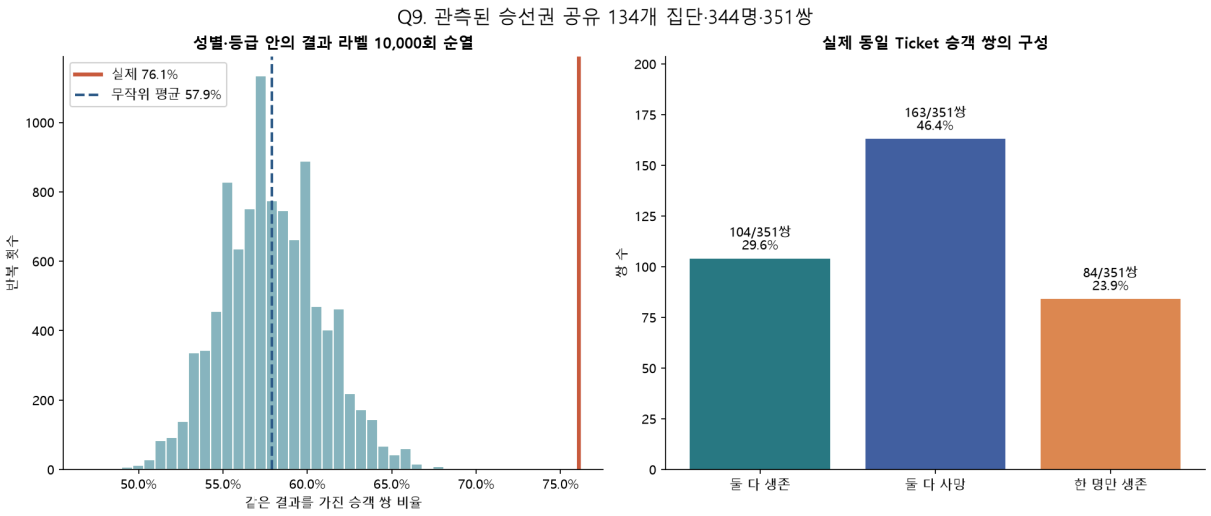
대상: 891명, 질문별 제외 0명. Q9의 891명은 순열 모집단이며 실제 승선권 공유 인원은 아래에 따로 표시한다.

대표 귀무가정: 성별·등급을 유지해 결과를 섞은 기준보다 실제 동일 Ticket 쌍의 일치율이 더 높지 않다. 단측 상방 대안이다.

방법: 동일 승선권 쌍 일치율, Sex×Pclass 내 10000회 단측 상방 순열

판정: 원 p=9.999e-05, Holm 보정 p=0.0008999. 대표 귀무가설 기각.

지표	결과
승선권 공유 집단	134개
해당 승객	344명
모든 가능한 승객 쌍	351쌍
둘 다 생존	104쌍
둘 다 사망	163쌍
같은 결과	267/351쌍 (76.07%)
조건부 무작위 기준 평균	57.9%
실제−무작위 평균	+18.18%p
무작위 통계량 2.5~97.5% 범위	52.42%~63.82%



관찰 결과

- 실제 일치율 76.07%는 성별·등급을 유지한 무작위 기준 평균 57.89%보다 18.18%p 높다.
- 같은 Ticket 승객의 결과가 함께 움직이는 패턴이 관찰됐다. 이는 예측 평가에서 동일 Ticket을 학습·평가 양쪽에 나누지 않은 이유와도 연결된다.

해석 범위·주의할 점

- 일치에는 둘 다 사망한 쌍도 포함된다. 승선권을 공유하면 생존율이 높아진다는 뜻이 아니다.
- 전체 쌍을 합쳐 계산하므로 큰 Ticket 집단은 가능한 쌍 수만큼 가중된다. 파일에 나타난 승객만 포함하고 모든 실제 동행자를 복원한 것이 아니다.
- 891명의 결과를 성별·등급 안에서 10000회 섞었다. 단독 승선권 승객도 섞기의 모집단에는 포함된다. 무작위 분포의 95% 범위는 관측 일치율의 신뢰구간이 아니다.

16.10. Q10 — 같은 성별·등급에서 train/test의 나이·요금·결측률은 다른가?

대상: 1309명, 질문별 제외 0명.

대표 귀무가정: 성별·등급 안에서 파일 라벨이 교환 가능하다. 나이·요금 중앙값과 결측률을 결합한 통계량으로 평가한다.

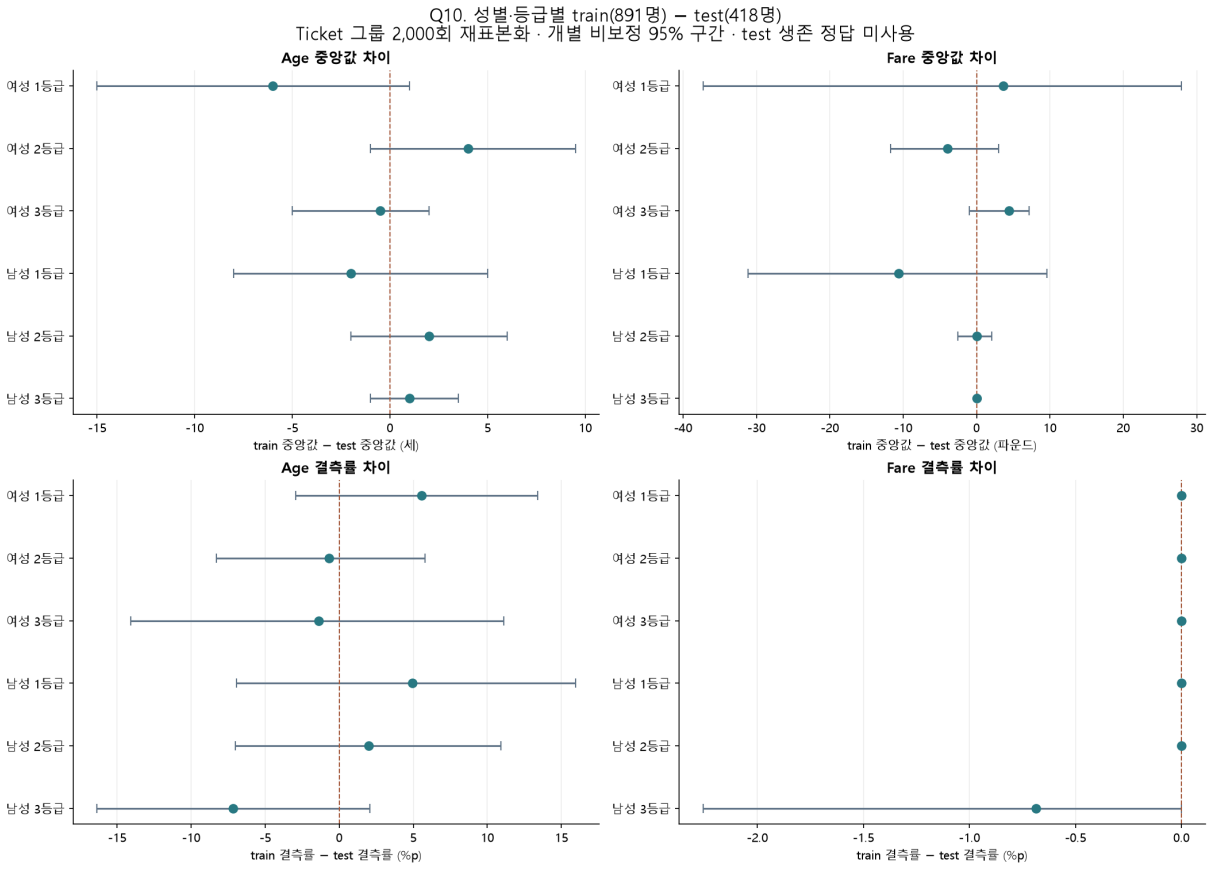
방법: 층별 IQR 표준화 중앙값·결측률 차이 제곱 가중 합, 파일 라벨 10000회 순열

판정: 원 p=0.1422, Holm 보정 p=0.2844. 대표 귀무가설을 기각할 근거 부족.

성별·등급	변수	관측 n(train/test)	train 중앙값	test 중앙값	차이(train−test)	개별 95% 구간
여성 1등급	Age	85/48	35.00	41.00	-6.00	[-15.00, +1.00]
여성 1등급	Fare	94/50	82.66	79.03	+3.64	[-37.28, +27.93]
여성 2등급	Age	74/29	28.00	24.00	+4.00	[-1.00, +9.50]
여성 2등급	Fare	76/30	22.00	26.00	-4.00	[-11.72, +3.00]
여성 3등급	Age	102/50	21.50	22.00	-0.50	[-5.00, +2.00]
여성 3등급	Fare	144/72	12.47	8.08	+4.39	[-1.00, +7.20]
남성 1등급	Age	101/50	40.00	42.00	-2.00	[-8.00, +5.00]
남성 1등급	Fare	122/57	41.26	51.86	-10.60	[-31.16, +9.55]
남성 2등급	Age	99/59	30.00	28.00	+2.00	[-2.00, +6.00]
남성 2등급	Fare	108/63	13.00	13.00	+0.00	[-2.58, +2.08]
남성 3등급	Age	253/96	25.00	24.00	+1.00	[-1.00, +3.50]
남성 3등급	Fare	347/145	7.92	7.90	+0.03	[+0.00, +0.20]

성별·등급	변수	전체 n(train/test)	train 결측률	test 결측률	차이(%p)	개별 95% 구간
여성 1등급	Age	94/50	9.6%	4.0%	+5.57	[-2.96, +13.41]
여성 1등급	Fare	94/50	0.0%	0.0%	+0.00	[+0.00, +0.00]

성별·등급	변수	전체 n(train/test)	train 결측률	test 결측률	차이(%p)	개별 95% 구간
여성 2등급	Age	76/30	2.6%	3.3%	-0.70	[-8.28, +5.80]
여성 2등급	Fare	76/30	0.0%	0.0%	+0.00	[+0.00, +0.00]
여성 3등급	Age	144/72	29.2%	30.6%	-1.39	[-14.06, +11.11]
여성 3등급	Fare	144/72	0.0%	0.0%	+0.00	[+0.00, +0.00]
남성 1등급	Age	122/57	17.2%	12.3%	+4.93	[-6.95, +15.95]
남성 1등급	Fare	122/57	0.0%	0.0%	+0.00	[+0.00, +0.00]
남성 2등급	Age	108/63	8.3%	6.3%	+1.98	[-7.01, +10.93]
남성 2등급	Fare	108/63	0.0%	0.0%	+0.00	[+0.00, +0.00]
남성 3등급	Age	347/146	27.1%	34.2%	-7.16	[-16.35, +2.08]
남성 3등급	Fare	347/146	0.0%	0.7%	-0.68	[-2.26, +0.00]



관찰 결과

- 여성 1등급의 나이 중앙값은 train 35세·test 41세로 −6세, 남성 1등급 요금 중앙값은 41.26·51.86파운드로 −10.60파운드다.
- 남성 3등급 나이 결측률은 train 27.1%·test 34.2%로 −7.16%p다. 그러나 대표 검정의 보정 p값 0.2844에서는 뚜렷한 공동 차이를 확인하지 못했다.

해석 범위·주의할 점

- 차이를 확인하지 못했다는 것은 두 파일이 동일하거나 모든 분포 특성이 같다는 증명이 아니다. 선택한 중앙값·결측률 통계량으로 조사한 결과다.
- 행 전체의 파일 라벨을 층 안에서 바꿔 나이·요금·결측의 결합구조를 유지했다. 구간은 같은 Ticket을 묶어 두 파일을 함께 재표본화했다.
- 빈도가 0인 결측 사건의 부트스트랩 구간이 [0,0]이어도 모집단 결측률이 정확히 0이라고 보장하지 않는다. test 생존 정답이나 모델 정확도는 사용하지 않았다.

아래 보고서는 이번 10개 질문의 모든 표·그래프·검정과 한계를 함께 담았다. 그림을 포함한 독립 HTML이며 원래 정제·모델 비교 보고서와 별도다.

attachment:4f8cff93-9b5c-4a55-93d2-0410ad24e7f1:team_questions_report.html

이번 추가 ZIP에는 질문 10개 계산 코드·실행 노트북·분석 기준 JSON·모든 결과표·순열 귀무 분포·그래프·전체 보고서·검증 기록이 들어 있다. 원본 CSV와 가상환경은 제외했다. 앞서 13절에 첨부한 전체 프로젝트 ZIP에 이번 실행 자료를 보완하는 파일이다.

titanic_team_questions.zip

추가 파일	내용
team_questions.py	Q1~Q10 실제 계산·순열·부트스트랩·대표 검정
team_questions_report.py	질문별 그래프·수치 해석·HTML 생성
team_questions.ipynb	실제 실행된 10개 질문 표·그래프·p값 재검증
team-questions-plan.json	통계량·기준·결측·보정·난수·가정
README_team_questions.md	팀원용 재실행 순서와 주의사항
output/team_questions/tables/	원 수치, 보조 표, 각 10,000회 순열 분포
output/team_questions/verification.json	독립적인 수치·검정·파일 검증 기록

16.12. 재실행·검증·출처

▼ 실행 방법

```
# 추가 ZIP을 기존 프로젝트 폴더에 합치거나 새 폴더에 푼 뒤 실행
py -3.12 -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt

# 원본 CSV가 이미 있으면 다운로드는 생략
.\.venv\Scripts\python.exe download_data.py

# 질문 10개 전체 계산과 그래프 생성
.\.venv\Scripts\python.exe team_questions.py

# 계산표·순열 분포를 유지하고 그래프·보고서만 생성
.\.venv\Scripts\python.exe team_questions.py --render-only
```

실행 노트북은 저장 결과를 불러와 순열 p값과 보정을 재검증한다. 처음부터 재계산하려면 마지막 셀의 RECOMPUTE=True를 사용한다. 원본이 이미 있으면 다운로드 스크립트는 덮어쓰지 않도록 오류를 내므로 해당 단계를 생략한다.

검증한 내용

- 원본 train/test 체크섬 보존.
- Q1·Q2의 상관 12개를 SciPy 스피어만 계산과 별도 대조.
- Q3·Q4·Q8의 중앙값·인원·차이와 재표본 유효 횟수 확인.
- Q5·Q7의 셀별 비율차와 Wald 자유도·p값 대조.
- Q6 Pearson 통계량을 SciPy 계산과 대조하고 889명·생존 340명 합계 확인.
- Q9 모든 351쌍을 직접 열거해 267쌍 일치를 확인. 조건부 귀무가정의 수학적 기대 일치율 57.93%도 계산해 시뮬레이션 평균 57.89%와 몬테카를로 오차 범위에서 일치함을 확인.
- Q10의 train/test 관측 인원·중앙값·결측률을 원본에서 다시 계산해 확인.
- 8개 순열 검정의 각 10,000회 통계량과 10개 Holm 보정값 재계산.
- 실제 실행 노트북 13개 코드 셀에 오류 없음, 그래프 10개 시각 확인.

방법 참고

- SciPy 스피어만 상관 — 소표본 층에 단순 점근 p값을 적용하는 대신 순열 기준을 사용했다.
- SciPy 순열 검정 — 교환가능성 귀무가정과 재표본 p값의 의미.
- statsmodels 군집 강건 공분산, Wald 검정, Holm 보정.
- 입력 데이터의 실제 다운로드 사본·대조 주소·체크섬은 2절과 첨부 다운로드 기록을 따른다. 새로운 외부 생존 정답을 가져오거나 test.csv의 결과를 추정해 검정에 넣지 않았다.